

Modele Markov Ascunse

De la Teorie la Aplicații

Alexandru Sorici, Tudor Berariu

Asociația Română pentru Inteligență Artificială
în colaborare cu
Laboratorul AI-MAS

7 noiembrie 2012



Outline

1 Aplicații în Învățarea Automată pentru MMA

- Învățarea Automată
- MMA în Învățarea Automată

Outline

1 Aplicații în Învățarea Automată pentru MMA

- Învățarea Automată
- MMA în Învățarea Automată

2 Teoria MMA

- Cele Trei Probleme ale MMA
- Fundamente Matematice

Outline

- 1 Aplicații în Învățarea Automată pentru MMA
 - Învățarea Automată
 - MMA în Învățarea Automată
- 2 Teoria MMA
 - Cele Trei Probleme ale MMA
 - Fundamente Matematice
- 3 Implementarea MMA
 - Problema Evaluării: Algoritmul Forward-Backward
 - Problema Interpretării: Algoritmul Viterbi
 - Problema Estimării: Algoritmul Baum-Welch

Outline

- 1 Aplicații în Învățarea Automată pentru MMA
 - Învățarea Automată
 - MMA în Învățarea Automată
- 2 Teoria MMA
 - Cele Trei Probleme ale MMA
 - Fundamente Matematice
- 3 Implementarea MMA
 - Problema Evaluării: Algoritmul Forward-Backward
 - Problema Interpretării: Algoritmul Viterbi
 - Problema Estimării: Algoritmul Baum-Welch
- 4 Demo: Recunoașterea Simbolurilor

Outline

- 1 Aplicații în Învățarea Automată pentru MMA
 - Învățarea Automată
 - MMA în Învățarea Automată
- 2 Teoria MMA
 - Cele Trei Probleme ale MMA
 - Fundamente Matematice
- 3 Implementarea MMA
 - Problema Evaluării: Algoritmul Forward-Backward
 - Problema Interpretării: Algoritmul Viterbi
 - Problema Estimării: Algoritmul Baum-Welch
- 4 Demo: Recunoașterea Simbolurilor
- 5 Tipuri de MMA

Outline

- 1 Aplicații în Învățarea Automată pentru MMA
 - Învățarea Automată
 - MMA în Învățarea Automată
- 2 Teoria MMA
 - Cele Trei Probleme ale MMA
 - Fundamente Matematice
- 3 Implementarea MMA
 - Problema Evaluării: Algoritmul Forward-Backward
 - Problema Interpretării: Algoritmul Viterbi
 - Problema Estimării: Algoritmul Baum-Welch
- 4 Demo: Recunoașterea Simbolurilor
- 5 Tipuri de MMA
- 6 Discuții și Concluzii



Outline

1 Aplicații în Învățarea Automată pentru MMA

- Învățarea Automată
- MMA în Învățarea Automată

2 Teoria MMA

- Cele Trei Probleme ale MMA
- Fundamente Matematice

3 Implementarea MMA

- Problema Evaluării: Algoritmul Forward-Backward
- Problema Interpretării: Algoritmul Viterbi
- Problema Estimării: Algoritmul Baum-Welch

4 Demo: Recunoașterea Simbolurilor

5 Tipuri de MMA

6 Discuții și Concluzii




Ce este Învățarea Automată?

Învățarea automată

Un program se spune că învăță dintr-o mulțime de experiențe E relativ la o clasă de task-uri T și o măsură a performanței P dacă performanța acestuia la execuția task-urilor T , măsurată de P , se îmbunătățește în urma experiențelor E . [Mit97]

Aplicații ale Învățării Automate

- Self-Driving Car: Google Car
- Traducere Automată: Google Translate
- Sisteme de Recomandare
 - Filme: ImDB, NetFlix
 - Publicitate Inteligentă: Google Ads, Facebook Ads





Aplicații ale Învățării Automate

- Self-Driving Car: Google Car
- Traducere Automată: Google Translate
- Sisteme de Recomandare
 - Filme: ImDB, NetFlix
 - Publicitate Inteligentă: Google Ads, Facebook Ads

A screenshot of the Google Translate interface. On the left, the source text "Bine ați venit la atelierul de lucru!" is displayed in Romanian, with a "Romanian - detected" label above it. On the right, the translated text "Welcome to the workshop!" is shown in English, with "English" above it. Both sections have "Romanian" and "Spanish" options at the top. Below each text area are small icons for a message bubble, a speaker, and a checkmark. A note at the bottom says: "New! Hold down the shift key, click, and drag the words above to reorder. Dismiss".



Aplicații ale Învățării Automate

- Self-Driving Car: Google Car
- Traducere Automată: Google Translate
- Sisteme de Recomandare
 - Filme: ImDB, NetFlix
 - Publicitate Intelligentă: Google Ads, Facebook Ads

Recommended for you

[Learn more](#)

Vicky Cristina Barcelona (2008)

PG-13 Drama | Romance

★★★★★ ★★★★★ 7.2 / 10

Two girlfriends on a summer holiday in Spain become enamored with the same painter, unaware that his ex-wife, with whom he has a tempestuous relationship, is about to re-enter the picture.

Director: Woody Allen
Stars: Rebecca Hall and Scarlett Johans...

Add to Watchlist

◀ Prev 6 Next ▶

No Next

Recommended because of your interest in Gegen die Wand and Closer.



Aplicații ale Învățării Automate


- Self-Driving Car: Google Car
- Traducere Automată: Google Translate
- Sisteme de Recomandare
 - Filme: ImDB, NetFlix
 - Publicitate Inteligentă: Google Ads, Facebook Ads

A screenshot of a Google search results page. The search bar at the top contains the query "caramizi". Below the search bar, there is a "Search" button and a message indicating "About 1,080,000 results (0.42 seconds)". On the left, there is a sidebar with categories: Web, Images, Videos, News, More, Bucharest, and Change location. The main content area shows search results. At the top of the results, there is an advertisement for "caramizi" from "Brikston.ro". The ad text reads: "Ad related to caramizi ① Construieste ieftin | brikston.ro www.brikston.ro/ Noul Brac are un pret de exceptie Si constructia ta avanseaza repede". Below the ad, there is a link to "Wienerberger - Wienerberger Sisteme de Caramizi Romania" with the URL "www.wienerberger.ro/". The page also mentions "Wienerberger este cel mai mare producător de caramizi din lume. Prin sistemul de blocuri ceramice POROTHERM și produsele TERCA Klinker pentru fațade și ... PRETURI recomandate - Calculaaza necesarul - Distributori - Pentru Specialisti". At the bottom of the results, there is another link: "Caramizi și blocuri ceramice - Brikston".

Învățarea Automată: Tipuri de probleme

Tipuri de probleme


- Regresie
 - predictia evolutiei pretului unui bun



Învățarea Automată: Tipuri de probleme

Tipuri de probleme

- Regresie
 - predicția evoluției prețului unui bun



Învățarea Automată: Tipuri de probleme

Tipuri de probleme


- Regresie
 - predicția evoluției prețului unui bun
- Clasificare
 - clasificarea obiectelor dintr-o imagine
(imagine de la Albert-Ludwigs-Universität, Lehrstuhl für Mustererkennung und Bildverarbeitung)



Învățarea Automată: Tipuri de probleme

Tipuri de probleme

- Regresie
 - predicția evoluției prețului unui bun
- Clasificare
 - clasificarea obiectelor dintr-o imagine
(imagine de la Albert-Ludwigs-Universität, Lehrstuhl für Mustererkennung und Bildverarbeitung)



Învățarea Automată: Tipuri de probleme

Tipuri de probleme

- Regresie
 - predicția evoluției prețului unui bun
- Clasificare
 - clasificarea obiectelor dintr-o imagine
(imagine de la Albert-Ludwigs-Universität, Lehrstuhl für Mustererkennung und Bildverarbeitung)
- Învățare prin Recompensă
 - jucător inteligent pentru backgammon





Tipuri de Învățare

Învățare Supervizată

Învățarea supervizată se face pe baza unor date de antrenare etichetate.

- construirea unui model climatic pe baza datelor din ultimii 30 de ani (regresie)
- construirea unui detector de mesaje spam (clasificare)



Tipuri de Învățare

Învățare Supervizată

Învățarea **supervizată** se face pe baza unor date de antrenare etichetate.

- construirea unui model climatic pe baza datelor din ultimii 30 de ani (regresie)
- construirea unui detector de mesaje spam (clasificare)

Învățare Nesupervizată

În **învățarea neupervizată** nu există date etichetate.

- detectarea profilurilor de comportament ale cumpărătorilor



Outline

1 Aplicații în Învățarea Automată pentru MMA

- Învățarea Automată
- MMA în Învățarea Automată

2 Teoria MMA

- Cele Trei Probleme ale MMA
- Fundamente Matematice

3 Implementarea MMA

- Problema Evaluării: Algoritmul Forward-Backward
- Problema Interpretării: Algoritmul Viterbi
- Problema Estimării: Algoritmul Baum-Welch

4 Demo: Recunoașterea Simbolurilor

5 Tipuri de MMA

6 Discuții și Concluzii



Probleme cu Secvențe Temporale (I)

URMĂRIREA OBIECTELOR

Urmărirea Vorbitorului GPS
Rachete Sol-Aer Robotică
 Sistem de Navigare pentru Nave

RECUNOAȘTEREA VORBIRII



Interfețe utilizator vocale
Procesare speech-to-text
Comanda Vocală Directă - Avioane

RECUNOAȘTEREA GESTURILOR

Recunoașterea Personalizată a Semnăturilor
Recunoașterea Limbajului Semenilor

Probleme cu Secvențe Temporale (I)


URMĂRIREA OBIECTELOR



RECUNOAȘTEREA VORBIRII





RECUNOAȘTEREA GESTURILOR



Probleme cu Secvențe Temporale (I)


URMĂRIREA OBIECTELOR



RECUNOAȘTEREA VORBIRII





RECUNOAȘTEREA GESTURILOR



Probleme cu Secvențe Temporale (I)

URMĂRIREA OBIECTELOR



RECUNOAȘTEREA VORBIRII





RECUNOAȘTEREA GESTURILOR



Probleme cu Secvențe Temporale (I)


URMĂRIREA OBIECTELOR



RECUNOAȘTEREA VORBIRII




RECUNOAȘTEREA GESTURILOR



Probleme cu Secvențe Temporale (I)


URMĂRIREA OBIECTELOR



RECUNOAȘTEREA VORBIRII



RECUNOAȘTEREA GESTURILOR





Probleme cu Secvențe Temporale (II)

BIOINFORMATICĂ

Secvențierea Proteinelor

Modelarea unei Rețele
Regulatoare Genetice

ECONOMIE

Predictia Valorilor
Bursiere

Econometrie
- estimarea în timp a indicatorilor economici ai unei țari -

Probleme cu Secvențe Temporale (II)

BIOINFORMATICĂ

Secvențierea Proteinelor

Modelarea unei Rețele
Regulatoare Genetice



ECONOMIE

**Predictia Valorilor
Bursiere**

Econometrie
- estimarea în timp a indicatorilor economici ai unei țari -



Rationament Probabilistic Temporal - Modele

Să ne gândim la unele din problemele anterioare ...



Rationament Probabilistic Temporal - Modele

Să ne gândim la unele din problemele anterioare ...

Cum modelăm astfel de situații dinamice?


Rationament Probabilistic Temporal - Modele

Să ne gândim la unele din problemele anterioare ...

Cum modelăm astfel de situații dinamice?

Stări și Observații

- Procesul de schimbare este văzut ca o serie de **snapshot-uri**
- Fiecare snapshot conține un set de variabile aleatoare
 - \mathbf{O}_t - setul tuturor variabilelor de măsurare (*observable*) la momentul t
 - \mathbf{Q}_t - setul tuturor variabilelor de stare (*neobservable / ascunse*) la momentul t



Exemplu: problemă de localizare a unui vehicul [KF09]



Rationament Probabilistic Temporal - Presupuneri

Să ne gândim la unele din problemele anterioare ...



Ratiōnament Probabilistic Temporal - Presupunerī

Să ne gândim la unele din problemele anterioare ...

Ce **presupunerī** facem?



Rationament Probabilistic Temporal - Presupuneri

Să ne gândim la unele din problemele anterioare ...

Ce **presupuneri** facem?

Proces staționar

Procesul de schimbare este guvernat de legi care **nu se schimba in timp**.

Urmare: trebuie să specificăm relațiile între variabile doar pentru un snapshot *reprezentativ*.



Rationament Probabilistic Temporal - Presupuneri

Să ne gândim la unele din problemele anterioare ...

Ce **presupuneri** facem?

Proces staționar

Procesul de schimbare este guvernat de legi care **nu se schimba in timp**.

Urmare: trebuie să specificăm relațiile între variabile doar pentru un snapshot *reprezentativ*.

Presupunerea Markov

Starea curentă a unui proces de schimbare depinde doar de o **istorie finită** de stări anterioare.

Urmare: avem un număr **limitat** de “parinți” pentru variabilele din fiecare snapshot.



Rationament Probabilistic Temporal - Inferență

Care sunt principalele inferențe ce se doresc făcute?



Raționament Probabilistic Temporal - Inferență

Care sunt principalele inferențe ce se doresc făcute?

Filtrare (monitorizare)

Sarcina de a calcula **starea de fapt** - distribuția posterioară de probabilitate a **stării curente**, date fiind toate observațiile de până acum.



Ratiونament Probabilistic Temporal - Inferență

Care sunt principalele inferențe ce se doresc făcute?

Filtrare (monitorizare)

Sarcina de a calcula **starea de fapt** - distribuția posterioară de probabilitate a **stării curente**, date fiind toate observațiile de până acum.

Evaluare

Sarcina de a calcula **probabilitatea (likelihood)** a observațiilor făcute până în prezent.



Ratiونament Probabilistic Temporal - Inferență

Care sunt principalele inferențe ce se doresc făcute?

Predictie

Sarcina de a calcula distribuția posterioară de probabilitate peste o **stare viitoare**, date fiind toate observațiile de până acum.



Ratiونament Probabilistic Temporal - Inferență

Care sunt principalele inferențe ce se doresc făcute?

Predictie

Sarcina de a calcula distribuția posterioară de probabilitate peste o **stare viitoare**, date fiind toate observațiile de până acum.

Netezire (hindsight)

Sarcina de a calcula distribuția posterioară de probabilitate peste o **stare anterioară**, date fiind toate observațiile de până acum.

Furnizează o estimare mai bună asupra stării respective, decât a fost posibil la momentul respectiv.



Raționament Probabilistic Temporal - Inferență

Care sunt principalele inferențe ce se doresc făcute?

Cea mai probabilă explicație

Dându-se o secvență de observații, se cere găsirea celei mai probabile secvenței de stări care a generat acele observații.



Raționament Probabilistic Temporal - Inferență

Care sunt principalele inferențe ce se doresc făcute?

Cea mai probabilă explicație

Dându-se o secvență de observații, se cere găsirea celei mai probabile secvenței de stări care a generat acele observații.


Învățare

Dându-se un set de secvențe de observații, găsește o metodă de a învăța modelele de tranzitie și senzoriale / de măsurare pe baza acestor observații.

Raționament Probabilistic Temporal - Metode

Rețele Bayesiene Dinamice (RBD)

O RBD este o rețea Bayesiană ce reprezintă un model temporal de probabilitate.




RBD simplificată pentru monitorizarea unui vehicul [KF09]

Aplicată în probleme precum: urmărirea obiectelor, recunoașterea activității umane, secvantierea proteinelor, etc.

Rationament Probabilistic Temporal - Metode

Filtre Kalman (Sistem Dinamice Lineare)

Un model temporal având una sau mai multe variabile care evoluează linear în timp, la care se adaugă **zgomot Gaussian**.



- Poate fi văzut ca o RBD în care toate variabilele sunt continue, iar dependențele sunt linear gaussiane.
- Aplicații multiple în **urmărirea obiectelor**

Structura unei RB pentru un sistem linear dinamic cu variabile de poziție X_t , viteză \dot{X}_t , și măsurare a poziției Z_t



Raționament Probabilistic Temporal - Metode

Modele Markov Ascunse (MMA)

Un MMA (HMM) este un model probabilistic temporal în care *starea* procesului de schimbare este descrisă de **o singură variabilă aleatoare discretă**. Valorile posibile ale variabilei reprezintă stările posibile ale lumii modelate.

Utilizat cu succes în aplicații precum:

- Recunoașterea Scrisului
- Recunoașterea Gesturilor
- Recunoașterea Vorbirii
- Determinarea Partilor de Vorbire (Part-of-Speech Tagging)
- Secvențiere ADN



Outline

1 Aplicații în Învățarea Automată pentru MMA

- Învățarea Automată
- MMA în Învățarea Automată

2 Teoria MMA

- Cele Trei Probleme ale MMA
- Fundamente Matematice

3 Implementarea MMA

- Problema Evaluării: Algoritmul Forward-Backward
- Problema Interpretării: Algoritmul Viterbi
- Problema Estimării: Algoritmul Baum-Welch

4 Demo: Recunoașterea Simbolurilor

5 Tipuri de MMA

6 Discuții și Concluzii



Cele 3 Probleme ale MMA

3 probleme fundamentale [Rab89]

- Particularizarea inferenței în probleme cu secvențe temporale pe cazul MMA
- Structura restricționată a MMA permite implementări elegante ale tuturor algoritmilor de bază



Cele 3 Probleme ale MMA

3 probleme fundamentale [Rab89]

- Particularizarea inferenței în probleme cu secvențe temporale pe cazul MMA
- Structura restricționată a MMA permite implementări elegante ale tuturor algoritmilor de bază

Problema Evaluării

Dându-se un model și o secvență de observații, cum calculăm probabilitatea ca **secvența observată** să fi fost produsă de model?



Cele 3 Probleme ale MMA

3 probleme fundamentale [Rab89]

- Particularizarea inferenței în probleme cu secvențe temporale pe cazul MMA
- Structura restricționată a MMA permite implementări elegante ale tuturor algoritmilor de bază

Problema Evaluării

Dându-se un model și o secvență de observații, cum calculăm probabilitatea ca secvența observată să fi fost produsă de model?

Problema Interpretării (cea mai bună explicație a observațiilor)

Dându-se un model și o secvență de observații, cum alegem o secvență corespunzătoare de stări care *dau sens* observațiilor?



Cele 3 Probleme ale MMA

3 probleme fundamentale [Rab89]

- Particularizarea inferenței în probleme cu secvențe temporale pe cazul MMA
- Structura restricționată a MMA permite implementări elegante ale tuturor algoritmilor de bază

Problema Evaluării

Dându-se un model și o secvență de observații, cum calculăm probabilitatea ca secvența observată să fi fost produsă de model?

Problema Interpretării (cea mai bună explicație a observațiilor)

Dându-se un model și o secvență de observații, cum alegem o secvență corespunzătoare de stări care dă sens observațiilor?

Problema Estimării (Antrenării) Modelului

Dându-se mai multe secvențe de observații, cum putem ajusta parametrii modelului MMA care explică cel mai bine observațiile făcute?



Outline

1 Aplicații în Învățarea Automată pentru MMA

- Învățarea Automată
- MMA în Învățarea Automată

2 Teoria MMA

- Cele Trei Probleme ale MMA
- **Fundamente Matematice**

3 Implementarea MMA

- Problema Evaluării: Algoritmul Forward-Backward
- Problema Interpretării: Algoritmul Viterbi
- Problema Estimării: Algoritmul Baum-Welch

4 Demo: Recunoașterea Simbolurilor

5 Tipuri de MMA

6 Discuții și Concluzii



O perspectivă teoretică asupra MMA


- Vom răspunde la următoarele întrebări:
 - ➊ Cum definim un Model Markov Ascuns?
 - ➋ Cum exprimăm cele trei întrebări fundamentale cu ajutorul probabilităților?

Ce este un MMA?

Definiție

Un **Model Markov Ascuns** este un dublu proces stocastic cu două componente:

- un proces Markov




Ce este un MMA?

Definiție

Un **Model Markov Ascuns** este un dublu proces stocastic cu două componente:

- un proces Markov *neobservabil (ascuns)*,
- un set de procese stocastice care produc partea *observabilă*.





Exemplu: Urmărirea stărilor emoționale

Să considerăm următorul exemplu:

- un robot ce urmărește evoluția stărilor emoționale ale unui om

Senzor:

- cameră video

Exemplu adaptat după :

R. Zubek. Introduction to hidden markov models. *AI Game Programming Wisdom*, 3:633–646, 2006

Exemplu: Urmărirea stărilor emoționale

s₁:vesel

s₂:trist

s₃:nervos


N - numărul de stări ascunse
S - mulțimea stărilor

$$N = 3$$

Stări:

- **s₁:** vesel
- **s₂:** trist
- **s₃**: nervos

Exemplu: Urmărirea stărilor emoționale



A - matricea distribuțiilor de probabilitate ale tranzițiilor între stări


$$\mathbf{A} = \{a_{i,j}\}, 1 \leq i, j \leq N$$

$$a_{i,j} = P(q_{t+1} = s_j | q_t = s_i)$$

$$\sum_{j=1}^N a_{i,j} = 1, \quad 1 \leq i \leq N$$

$$\mathbf{A} = \begin{pmatrix} s_1 & s_2 & s_3 \\ s_1 & 0.8 & 0.1 & 0.1 \\ s_2 & 0.1 & 0.8 & 0.1 \\ s_3 & 0.1 & 0.1 & 0.8 \end{pmatrix}$$

Exemplu: Urmărirea stărilor emoționale



A - matricea distribuțiilor de probabilitate ale tranzițiilor între stări


$$\mathbf{A} = \{a_{i,j}\}, 1 \leq i, j \leq N$$

$$a_{i,j} = P(q_{t+1} = s_j | q_t = s_i)$$

$$\sum_{j=1}^N a_{i,j} = 1, \quad 1 \leq i \leq N$$

$$\mathbf{A} = \begin{pmatrix} s_1 & s_2 & s_3 \\ s_1 & 0.8 & 0.1 & 0.1 \\ s_2 & 0.25 & 0.25 & 0.5 \\ s_3 & & & \end{pmatrix}$$

Exemplu: Urmărirea stărilor emoționale



A - matricea distribuțiilor de probabilitate ale tranzițiilor între stări


$$\mathbf{A} = \{a_{i,j}\}, 1 \leq i, j \leq N$$

$$a_{i,j} = P(q_{t+1} = s_j | q_t = s_i)$$

$$\sum_{j=1}^N a_{i,j} = 1, \quad 1 \leq i \leq N$$

$$\mathbf{A} = \begin{pmatrix} s_1 & s_2 & s_3 \\ s_1 & 0.8 & 0.1 & 0.1 \\ s_2 & 0.25 & 0.25 & 0.5 \\ s_3 & 0.8 & 0.2 & 0 \end{pmatrix}$$

Exemplu: Urmărirea stărilor emoționale




Π - distribuția stării inițiale

$$\Pi = \{\pi_i\}, \quad 1 \leq i \leq N$$

$$\pi_i = P(q_1 = s_i)$$

$$\Pi = \begin{pmatrix} s_1 & s_2 & s_3 \\ 0.7 & 0.2 & 0.1 \end{pmatrix}$$

Exemplu: Urmărirea stărilor emoționale




Deocamdată am descris un proces Markov.

$$A = \begin{pmatrix} s_1 & s_2 & s_3 \\ s_1 & 0.8 & 0.1 & 0.1 \\ s_2 & 0.25 & 0.25 & 0.5 \\ s_3 & 0.8 & 0.2 & 0 \end{pmatrix}$$

$$\Pi = \begin{pmatrix} s_1 & s_2 & s_3 \\ 0.7 & 0.2 & 0.1 \end{pmatrix}$$

Exemplu: Urmărirea stărilor emoționale



vesel → vesel → nervos → trist

$$\mathbf{Q} = [q_1:s_1 \ q_2:s_1 \ q_3:s_3 \ q_4:s_2]$$

Deocamdată am descris un proces Markov.

$$A = \begin{pmatrix} s_1 & s_2 & s_3 \\ s_1 & 0.8 & 0.1 & 0.1 \\ s_2 & 0.25 & 0.25 & 0.5 \\ s_3 & 0.8 & 0.2 & 0 \end{pmatrix}$$

$$\Pi = \begin{pmatrix} s_1 & s_2 & s_3 \\ 0.7 & 0.2 & 0.1 \end{pmatrix}$$

Notație: $\mathbf{Q} = [q_1 q_2 \cdots q_T]$

$$P(Q|A, \Pi) = \pi_{q_1} a_{q_1, q_2} \cdots a_{q_{T-1}, q_T}$$

$$\begin{aligned} P(s_1, s_1, s_3, s_2 | A, \Pi) &= \pi_1 \cdot a_{1,1} \cdot a_{1,3} \cdot a_{3,2} = \\ &= 0.8 \cdot 0.8 \cdot 0.1 \cdot 0.2 = 0.0128 \end{aligned}$$

Exemplu: Urmărirea stărilor emoționale

s_1 : vesel s_2 : trist s_3 : nervos

v_1 : zâmbet / rânjet

v_2 : nimic

v_3 : încruntare


M - numărul de valori observabile distincte

$$M = 3$$

valori observabile:

- v_1 : zâmbet / rânjet
- v_2 : nimic
- v_3 : încruntare

Exemplu: Urmărirea stărilor emoționale



B - matricea distribuțiilor de probabilitate ale valorilor observabile


$$\mathbf{B} = \{b_{j,k}\}_{1 \leq j \leq N, 1 \leq k \leq M}$$

$$\begin{aligned} b_{j,k} &= b_j(v_k) \\ &= P(o_t = v_k | q_t = s_j) \end{aligned}$$

$$\sum_{k=1}^M b_{j,k} = 1, \quad 1 \leq j \leq N$$

$$\mathbf{B} = \begin{matrix} & v_1 & v_2 & v_3 \\ \begin{matrix} s_1 \\ s_2 \\ s_3 \end{matrix} & \left(\begin{matrix} 0.7 & 0.3 & 0 \end{matrix} \right) \end{matrix}$$

Exemplu: Urmărirea stărilor emoționale



B - matricea distribuțiilor de probabilitate ale valorilor observabile


$$\mathbf{B} = \{b_{j,k}\}_{1 \leq j \leq N, 1 \leq k \leq M}$$

$$\begin{aligned} b_{j,k} &= b_j(v_k) \\ &= P(o_t = v_k | q_t = s_j) \end{aligned}$$

$$\sum_{k=1}^M b_{j,k} = 1, \quad 1 \leq j \leq N$$

$$\mathbf{B} = \begin{matrix} & v_1 & v_2 & v_3 \\ \begin{matrix} s_1 \\ s_2 \\ s_3 \end{matrix} & \left(\begin{matrix} 0.7 & 0.3 & 0 \\ 0 & 0.7 & 0.3 \end{matrix} \right) \end{matrix}$$

Exemplu: Urmărirea stărilor emoționale



B - matricea distribuțiilor de probabilitate ale valorilor observabile


$$\mathbf{B} = \{b_{j,k}\}_{1 \leq j \leq N, 1 \leq k \leq M}$$

$$\begin{aligned} b_{j,k} &= b_j(v_k) \\ &= P(o_t = v_k | q_t = s_j) \end{aligned}$$

$$\sum_{k=1}^M b_{j,k} = 1, \quad 1 \leq j \leq N$$

$$\mathbf{B} = \begin{pmatrix} v_1 & v_2 & v_3 \\ s_1 & 0.7 & 0.3 & 0 \\ s_2 & 0 & 0.7 & 0.3 \\ s_3 & 0.6 & 0 & 0.4 \end{pmatrix}$$

Exemplu: Urmărirea stărilor emoționale



λ - parametrii Modelului Markov Ascuns


$$\lambda = (A, B, \Pi)$$

A - matricea distribuțiilor de probabilitate ale tranzițiilor între stări

B - matricea distribuțiilor de probabilitate ale valorilor observabile

Π - distribuția stării inițiale

Exemplu: Urmărirea stărilor emoționale




$$O = [o_1:zâmbet \quad o_2:nimic \quad o_3:nimic \\ \quad o_4:încruntare \quad o_5:zâmbet]$$

O - secvența de observații

T - lungimea secvenței de observații

$$O = [o_1 o_2 \dots o_T]$$

Exemplu: Urmărirea stărilor emoționale




zâmbet, nimic, nimic, încruntare, zâmbet

O - secvența de observații

T - lungimea secvenței de observații

$$O = [o_1 o_2 \cdots o_T]$$

Exemplu: Urmărirea stărilor emoționale



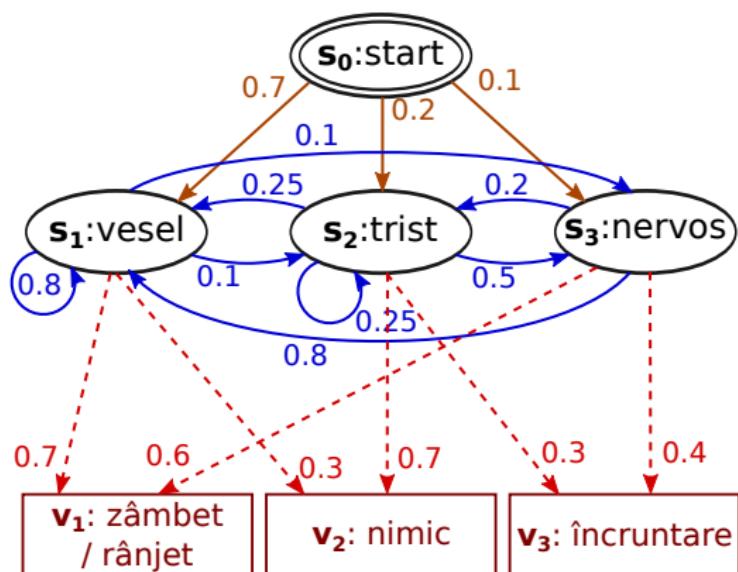
$\text{vesel} \rightarrow \text{vesel} \rightarrow \text{vesel} \rightarrow \text{trist} \rightarrow \text{nervos}$
 zâmbet, nimic, nimic, încruntare, zâmbet

O - secvența de observații

T - lungimea secvenței de observații

$$O = [o_1 o_2 \cdots o_T]$$

Exemplu: Urmărirea stărilor emotionale



vesel → vesel → vesel → trist → nervos
 zâmbet, nimic, nimic, încruntare, zâmbet
 nervos → trist → trist → nervos → vesel

O - secvența de observații

T - lungimea secvenței de observații


$$O = [o_1 o_2 \cdots o_T]$$

Modele Markov Ascunse

Definiție

Un **Model Markov Ascuns** este un tuplu $\langle S, V, A, B, P \rangle$:

- S - mulțimea stărilor
 - V - mulțimea valorilor observabile
 - A - matricea de tranziție
 - B - matricea de emisie
 - Π - matricea distribuției stării inițiale
-
- Notație: $\lambda = (A, B, \Pi)$ - parametrii modelului





Reformularea problemelor fundamentale ale MMA

Problema evaluării

Date fiind un model și o secvență de observații , cum calculăm probabilitatea ca secvența de observații să fi fost generată de acel model?

Reformularea problemelor fundamentale ale MMA

Problema evaluării

Date fiind un model $\lambda = (A, B, \Pi)$ și o secvență de observații $O = [o_1 o_2 \cdots o_T]$, cum calculăm probabilitatea $P(O|\lambda)$ ca secvența de observații să fi fost generată de acel model?



Reformularea problemelor fundamentale ale MMA

Problema evaluării

Date fiind un model $\lambda = (A, B, \Pi)$ și o secvență de observații $O = [o_1 o_2 \cdots o_T]$, cum calculăm probabilitatea $P(O|\lambda)$ ca secvența de observații să fi fost generată de acel model?

- Prin enumerarea tuturor secvențelor posibile de stări:

$$P(O|\lambda) = \sum_{\text{all } Q} P(O|Q, \lambda) \cdot P(Q|\lambda) \quad (1)$$

(legea probabilității totale)



Reformularea problemelor fundamentale ale MMA

$$P(O|\lambda) = \sum_{\text{all } Q} P(O|Q, \lambda) \cdot P(Q|\lambda) \quad (1)$$



Reformularea problemelor fundamentale ale MMA

$$P(O|\lambda) = \sum_{\text{all } Q} P(O|Q, \lambda) \cdot P(Q|\lambda) \quad (1)$$

Primul factor (independență condițională):

$$P(O|Q, \lambda) = \prod_{t=1}^T P(o_t|q_t, \lambda) = \prod_{t=1}^T b_{q_t}(o_t) = b_{q_1}(o_1) \cdot \dots \cdot b_{q_T}(o_T) \quad (2)$$



Reformularea problemelor fundamentale ale MMA

$$P(O|\lambda) = \sum_{\text{all } Q} P(O|Q, \lambda) \cdot P(Q|\lambda) \quad (1)$$

Primul factor (independență condițională):

$$P(O|Q, \lambda) = \prod_{t=1}^T P(o_t|q_t, \lambda) = \prod_{t=1}^T b_{q_t}(o_t) = b_{q_1}(o_1) \cdot \dots \cdot b_{q_T}(o_T) \quad (2)$$

Al doilea factor (presupunerea Markov):

$$P(Q|\lambda) = \pi_{q_1} \prod_{t=2}^T a_{q_{t-1}, q_t} = \pi_{q_1} \cdot a_{q_1, q_2} \cdot a_{q_2, q_3} \cdot \dots \cdot a_{q_{T-1}, q_T} \quad (3)$$

Reformularea problemelor fundamentale ale MMA

$$P(O|\lambda) = \sum_{\text{all } Q} P(O|Q, \lambda) \cdot P(Q|\lambda) \quad (1)$$

Primul factor (independență condițională):

$$P(O|Q, \lambda) = \prod_{t=1}^T P(o_t|q_t, \lambda) = \prod_{t=1}^T b_{q_t}(o_t) = b_{q_1}(o_1) \cdot \dots \cdot b_{q_T}(o_T) \quad (2)$$

Al doilea factor (presupunerea Markov):

$$P(Q|\lambda) = \pi_{q_1} \prod_{t=2}^T a_{q_{t-1}, q_t} = \pi_{q_1} \cdot a_{q_1, q_2} \cdot a_{q_2, q_3} \cdot \dots \cdot a_{q_{T-1}, q_T} \quad (3)$$

$$P(O|\lambda) = \sum_{\text{all } Q} \left(\pi_{q_1} \cdot b_{q_1}(o_1) \cdot \prod_{t=2}^T b_{q_t}(o_t) a_{q_{t-1}, q_t} \right) \quad (1)$$



Reformularea problemelor fundamentale ale MMA

Problema interpretării unei secvențe de observații

Date fiind un model și o secvență de observații
, cum alegem o secvență corespunzătoare de stări
care să dea *un înțeles* observațiilor? Cum *descoperim*
partea ascunsă a modelului?



Reformularea problemelor fundamentale ale MMA

Problema interpretării unei secvențe de observații

Date fiind un model $\lambda = (A, B, \Pi)$ și o secvență de observații
, cum alegem o secvență corespunzătoare de stări
care să dea *un înțeles* observațiilor? Cum *descoperim*
partea ascunsă a modelului?



Reformularea problemelor fundamentale ale MMA

Problema interpretării unei secvențe de observații

Date fiind un model $\lambda = (A, B, \Pi)$ și o secvență de observații

$O = [o_1 o_2 \cdots o_T]$, cum alegem o secvență corespunzătoare de stări
care să dea un înțeles observațiilor? Cum descoperim
partea ascunsă a modelului?



Reformularea problemelor fundamentale ale MMA

Problema interpretării unei secvențe de observații

Date fiind un model $\lambda = (A, B, \Pi)$ și o secvență de observații

$O = [o_1 o_2 \cdots o_T]$, cum alegem o secvență corespunzătoare de stări

$Q = [q_1 q_2 \cdots q_T]$ care să dea un înțeles observațiilor? Cum descoperim partea ascunsă a modelului?



Reformularea problemelor fundamentale ale MMA

Problema interpretării unei secvențe de observații

Date fiind un model $\lambda = (A, B, \Pi)$ și o secvență de observații

$O = [o_1 o_2 \cdots o_T]$, cum alegem o secvență corespunzătoare de stări

$Q = [q_1 q_2 \cdots q_T]$ care să dea un înțeles observațiilor? Cum descoperim partea ascunsă a modelului?

- Există mai multe criterii pentru *cea mai bună* sevență
 - Secvența celor mai probabile stări (luate individual):

$$Q_{\text{best}} = [\hat{q}_1 \hat{q}_2 \dots \hat{q}_T], \quad \hat{q}_t = \underset{s_i}{\operatorname{argmax}} P(q_t = s_i | O, \lambda) \quad (4)$$

Reformularea problemelor fundamentale ale MMA

Problema interpretării unei secvențe de observații

Date fiind un model $\lambda = (A, B, \Pi)$ și o secvență de observații

$O = [o_1 o_2 \cdots o_T]$, cum alegem o secvență corespunzătoare de stări

$Q = [q_1 q_2 \cdots q_T]$ care să dea un înțeles observațiilor? Cum descoperim partea ascunsă a modelului?

- Există mai multe criterii pentru *cea mai bună* sevență
 - Secvența celor mai probabile stări (luate individual):

$$Q_{\text{best}} = [\hat{q}_1 \hat{q}_2 \dots \hat{q}_T], \quad \hat{q}_t = \underset{s_i}{\operatorname{argmax}} P(q_t = s_i | O, \lambda) \quad (4)$$

- Cea mai bună *cale* (de dimensiune T)

$$Q_{\text{best}} = \underset{Q}{\operatorname{argmax}} P(Q | O, \lambda) = \underset{Q}{\operatorname{argmax}} P(Q, O | \lambda) \quad (5)$$



Reformularea problemelor fundamentale ale MMA

Problema Estimării Modelului (Învățării)

Date fiind niște secvențe de observații , cum *ajustăm parametrii* ai unui MMA astfel încât să explice cel mai bine observațiile?



Reformularea problemelor fundamentale ale MMA

Problema Estimării Modelului (Învățării)

Date fiind niște secvențe de observații $\mathcal{O} = [O_1 O_2 \cdots O_L]$, cum *ajustăm parametrii* ai unui MMA astfel încât să explice cel mai bine observațiile?

Reformularea problemelor fundamentale ale MMA

Problema Estimării Modelului (Învățării)

Date fiind niște secvențe de observații $\mathcal{O} = [O_1 O_2 \cdots O_L]$, cum *ajustăm parametrii* $\lambda = (A, B, \Pi)$ ai unui MMA astfel încât să explice cel mai bine observațiile?

Reformularea problemelor fundamentale ale MMA

Problema Estimării Modelului (Învățării)

Date fiind niște secvențe de observații $\mathcal{O} = [O_1 O_2 \cdots O_L]$, cum *ajustăm parametrii* $\lambda = (A, B, \Pi)$ ai unui MMA astfel încât să explice cel mai bine observațiile?

- Întrebarea se poate reformula matematic:

$$\lambda_{\text{best}} = \underset{\lambda}{\operatorname{argmax}} P(\mathcal{O}|\lambda) \quad (6)$$



De înlocuit

:)



Outline

1 Aplicații în Învățarea Automată pentru MMA

- Învățarea Automată
- MMA în Învățarea Automată

2 Teoria MMA

- Cele Trei Probleme ale MMA
- Fundamente Matematice

3 Implementarea MMA

- Problema Evaluării: Algoritmul Forward-Backward
- Problema Interpretării: Algoritmul Viterbi
- Problema Estimării: Algoritmul Baum-Welch

4 Demo: Recunoașterea Simbolurilor

5 Tipuri de MMA

6 Discuții și Concluzii



Algoritmul Forward-Backward

Problema Evaluării

Date fiind un model $\lambda = (A, B, \Pi)$ și o secvență de observații $O = [o_1 o_2 \dots o_T]$, care este probabilitatea ca secvența de observații să fi fost produsă de acel model?

$$P(O|\lambda) = ? \quad (7)$$



Algoritmul Forward-Backward

Problema Evaluării

Date fiind un model $\lambda = (A, B, \Pi)$ și o secvență de observații $O = [o_1 o_2 \dots o_T]$, care este probabilitatea ca secvența de observații să fi fost produsă de acel model?

$$P(O|\lambda) = ? \quad (7)$$

Rezolvare

$P(O|\lambda)$ se calculează *eficient* cu algoritmul **Forward - Backward**.

Calculul se face cu ajutorul unor variabile auxiliare α și β .



Variabilele α - Motivație

- Calcul conform legii probabilităților totale:

$$\begin{aligned}
 P(O|\lambda) &= \sum_{\text{all } Q} P(O, Q|\lambda) = \sum_{\text{all } Q} P(O, |Q, \lambda) \cdot P(Q, \lambda) \\
 &= \sum_{\text{all } Q} \left(\pi_{q_1} \cdot b_{q_1}(o_1) \cdot \prod_{t=2}^T b_{q_t}(o_t) a_{q_{t-1}, q_t} \right)
 \end{aligned} \tag{1}$$

- Pentru secvențele de stări care încep cu o secvență comună $[q_1 q_2 \dots q_Z]$, următorii factori sunt comuni:

$$\pi_{q_1} \cdot b_{q_1}(o_1) \cdot \prod_{z=2}^Z b_{q_z}(o_z) a_{q_{z-1}, q_z}$$

- Calculul de $(T - Z)^N$ ori ar fi redundant!



Variabilele α - Definiție

Definim variabilele α astfel:

$$\alpha_{t,i} = P(o_1, o_2, \dots, o_t, q_t = s_i | \lambda) \quad (8)$$

$1 \leq t \leq T, 1 \leq i \leq N$

(probabilitatea de a fi observat primele t valori observate ajungând la momentul t în starea s_i , dați fiind parametrii λ)



Variabilele α - Definiție

Definim variabilele α astfel:

$$\alpha_{t,i} = P(o_1, o_2, \dots, o_t, q_t = s_i | \lambda) \quad (8)$$

$1 \leq t \leq T, 1 \leq i \leq N$

(probabilitatea de a fi observat primele t valori observate ajungând la momentul t în starea s_i , dați fiind parametrii λ)

Relația dintre $P(O|\lambda)$ și variabilele α este:

$$P(O|\lambda) = \sum_{i=1}^N \alpha_{T,i} \quad (9)$$


(conform legii probabilităților totale)



Calculul variabilelor α

- Initializare ($t = 1$)


$$\alpha_{1,i} = \pi_i b_i(o_1), \quad 1 \leq i \leq N$$



Calculul variabilelor α

- Initializare ($t = 1$)

$$\alpha_{1,i} = \pi_i b_i(o_1), \quad 1 \leq i \leq N$$




- Inducție ($t > 1$)

$$\alpha_{t+1,j} = \left[\sum_{i=1}^N \alpha_{t,i} a_{i,j} \right] b_j(o_{t+1}), \quad \begin{matrix} 1 \leq t \leq T-1 \\ 1 \leq j \leq N \end{matrix}$$

Calculul variabilelor α

- Initializare ($t = 1$)

$$\alpha_{1,i} = \pi_i b_i(o_1), \quad 1 \leq i \leq N$$



- Inducție ($t > 1$)

$$\alpha_{t+1,j} = \left[\sum_{i=1}^N \alpha_{t,i} a_{i,j} \right] b_j(o_{t+1}), \quad \begin{matrix} 1 \leq t \leq T-1 \\ 1 \leq j \leq N \end{matrix}$$

- Probabilitatea secvenței observate:

$$P(O|\lambda) = \sum_{i=1}^N \alpha_{T,i}$$



Variabilele β - Definiție

Definim variabilele β astfel:

$$\beta_{t,i} = P(o_{t+1} o_{t+2} \cdots o_T | q_t = s_i, \lambda) \quad (10)$$

(probabilitatea de a fi observate valorile secvenței de la $t + 1$ la T , condiționată de aflarea la momentul t în starea s_i și de parametrii λ)



Variabilele β - Definiție

Definim variabilele β astfel:

$$\beta_{t,i} = P(o_{t+1} o_{t+2} \cdots o_T | q_t = s_i, \lambda) \quad (10)$$


(probabilitatea de a fi observate valorile secvenței de la $t + 1$ la T , condiționată de aflarea la momentul t în starea s_i și de parametrii λ)

Relația dintre $P(O|\lambda)$ și variabilele β este:

$$P(O|\lambda) = \sum_{i=1}^N \beta_{1,i} \quad (11)$$

(conform legii probabilităților totale)

Calculul Variabilelor β



- Pas de inducție ($t < T$)

$$\beta_{t,i} = \sum_{j=1}^N a_{i,j} b_j(o_{t+1}) \beta_{t+1,j}, \quad t = T-1, T-2, \dots, 1, 1 \leq i \leq N$$

- Inițializare ($t = T$)

$$\beta_{T,i} = 1, \quad 1 \leq i \leq N \quad (12)$$



Probleme numerice

- să revedem definiția $P(O|\lambda)$:

$$P(O|\lambda) = \sum_{\text{all } Q} \left(\pi_{q_1} \cdot b_{q_1}(o_1) \cdot \prod_{t=2}^T b_{q_t}(o_t) a_{q_{t-1}, q_t} \right)$$



Probleme numerice

- să revedem definiția $P(O|\lambda)$:

$$P(O|\lambda) = \sum_{\text{all } Q} \left(\pi_{q_1} \cdot b_{q_1}(o_1) \cdot \prod_{t=2}^T b_{q_t}(o_t) a_{q_{t-1}, q_t} \right)$$

- toți cei $2T$ factori ai unui produs sunt subunitari
- pentru secvențe mari, produsele se apropie mult de zero
- se depășește precizia disponibilă pentru reprezentare
- trebuie introdus un mecanism de **scalare**



Algoritmul Forward-Backward cu scalare

- $\hat{\alpha}_{t,i}$ - variabilele α scalate
- $\hat{\beta}_{t,i}$ - variabilele β scalate
- C_t - coeficienții de scalare
- Variabilele α scalate

$$\hat{\alpha}_{t,i} = C_t \cdot \alpha_{t,i} \quad (13)$$

- Variabilele β scalate:

$$\hat{\beta}_{t,j} = C_t \cdot \beta_{t,j} \quad (14)$$

(notăriile sunt adoptate din literatură)



Calculul variabilelor α scalate

- Inițializare
 $(t = 1)$

$$1 \leq i \leq N$$

$$\ddot{\alpha}_{1,i} = \alpha_{1,i} \quad (15)$$

$$c_1 = \frac{1}{\sum_{i=1}^N \ddot{\alpha}_{1,i}} \quad (16)$$

$$\hat{\alpha}_{1,i} = c_1 \cdot \ddot{\alpha}_{1,i} \quad (17)$$



Calculul variabilelor α scalate

- Inițializare
($t = 1$)

$$1 \leq i \leq N$$

$$\ddot{\alpha}_{1,i} = \alpha_{1,i} \quad (15)$$

$$c_1 = \frac{1}{\sum_{i=1}^N \ddot{\alpha}_{1,i}} \quad (16)$$

$$\hat{\alpha}_{1,i} = c_1 \cdot \ddot{\alpha}_{1,i} \quad (17)$$

- Pas de inducție

$$(t > 1)$$

$$1 \leq i \leq N$$

$$\ddot{\alpha}_{t+1,i} = \left[\sum_{i=1}^N \hat{\alpha}_{t,i} a_{i,j} \right] b_j(o_{t+1}) \quad (18)$$

$$c_{t+1} = \frac{1}{\sum_{i=1}^N \ddot{\alpha}_{t+1,i}} \quad (19)$$

$$\hat{\alpha}_{t+1,i} = c_{t+1} \cdot \ddot{\alpha}_{t+1,i} \quad (20)$$



Coeficientii de scalare

Vom nota: $C_t = c_1 \cdot c_2 \cdot \dots \cdot c_t$

Ipoteza: $\hat{\alpha}_{t,i} = C_t \alpha_{t,i}$



Coeficientii de scalare

Vom nota: $C_t = c_1 \cdot c_2 \cdot \dots \cdot c_t$

Ipoteza: $\hat{\alpha}_{t,i} = C_t \alpha_{t,i}$

Demonstrație prin inducție:

- ($t = 1$):

$$\hat{\alpha}_{1,i} = c_1 \cdot \ddot{\alpha}_{1,i} = c_1 \cdot \alpha_{1,i}$$



Coeficientii de scalare

Vom nota: $C_t = c_1 \cdot c_2 \cdot \dots \cdot c_t$

Ipoteza: $\hat{\alpha}_{t,i} = C_t \alpha_{t,i}$

Demonstrație prin inducție:

- ($t = 1$):

$$\hat{\alpha}_{1,i} = c_1 \cdot \ddot{\alpha}_{1,i} = c_1 \cdot \alpha_{1,i}$$

- ($t > 1$): Presupunem adevărat: $\hat{\alpha}_{t,i} = C_t \alpha_{t,i}$

$$\ddot{\alpha}_{t+1,i} = \left[\sum_{i=1}^N \hat{\alpha}_{t,i} a_{i,j} \right] b_j(o_{t+1}) = \left[\sum_{i=1}^N C_t \alpha_{t,i} a_{i,j} \right] b_j(o_{t+1}) = C_t \alpha_{t+1,i}$$

$$\hat{\alpha}_{t+1,i} = c_{t+1} \cdot \ddot{\alpha}_{t+1,i} = c_{t+1} \cdot C_t \cdot \alpha_{t+1,i} = C_{t+1} \cdot \alpha_{t+1,i}$$



Coeficientii de scalare

Vom nota: $C_t = c_1 \cdot c_2 \cdot \dots \cdot c_t$

Ipoteza: $\hat{\alpha}_{t,i} = C_t \alpha_{t,i}$

Atunci: $P(\mathbf{O}|\lambda) = \sum_{i=1}^N \alpha_{T,i} = C_T^{-1} \cdot \sum_{i=1}^N \hat{\alpha}_{T,i} = C_T^{-1} = \prod_{t=1}^T c_t^{-1}$



Coeficientii de scalare

Vom nota: $C_t = c_1 \cdot c_2 \cdot \dots \cdot c_t$

Ipoteza: $\hat{\alpha}_{t,i} = C_t \alpha_{t,i}$

Atunci: $P(\mathbf{O}|\lambda) = \sum_{i=1}^N \alpha_{T,i} = C_T^{-1} \cdot \sum_{i=1}^N \hat{\alpha}_{T,i} = C_T^{-1} = \prod_{t=1}^T c_t^{-1}$

Calculăm $P(O|\lambda)$?



Coeficientii de scalare

Vom nota: $C_t = c_1 \cdot c_2 \cdot \dots \cdot c_t$

Ipoteza: $\hat{\alpha}_{t,i} = C_t \alpha_{t,i}$

Atunci: $P(\mathbf{O}|\lambda) = \sum_{i=1}^N \alpha_{T,i} = C_T^{-1} \cdot \sum_{i=1}^N \hat{\alpha}_{T,i} = C_T^{-1} = \prod_{t=1}^T c_t^{-1}$

Calculăm $P(O|\lambda)$? **NU**



Coeficientii de scalare

Vom nota: $C_t = c_1 \cdot c_2 \cdot \dots \cdot c_t$

Ipoteza: $\hat{\alpha}_{t,i} = C_t \alpha_{t,i}$

$$\text{Atunci: } P(\mathbf{O}|\lambda) = \sum_{i=1}^N \alpha_{T,i} = C_T^{-1} \cdot \sum_{i=1}^N \hat{\alpha}_{T,i} = C_T^{-1} = \prod_{t=1}^T c_t^{-1}$$

Calculăm $P(O|\lambda)$? **NU**

Calculăm:

$$\log(P(O|\lambda)) = \log\left(\prod_{t=1}^T c_t^{-1}\right) = \sum_{t=1}^T \log(c_t^{-1}) = -\sum_{t=1}^T \log(c_t) \quad (21)$$



Calculul variabilelor β scalate

- Inițializare

$$(t = T)$$

$$\ddot{\beta}_{T,i} = \beta_{T,i} = 1 \quad (22)$$

$$1 \leq i \leq N$$

$$\hat{\beta}_{T,i} = c_T \cdot \ddot{\beta}_{T,i} \quad (23)$$



Calculul variabilelor β scalate

- Inițializare

$$(t = T)$$

$$\ddot{\beta}_{T,i} = \beta_{T,i} = 1 \quad (22)$$

$$1 \leq i \leq N$$

$$\hat{\beta}_{T,i} = c_T \cdot \ddot{\beta}_{T,i} \quad (23)$$

- Pas de inducție

$$(t < T)$$

$$\ddot{\beta}_{t,i} = \sum_{j=1}^N a_{i,j} b_j(o_{t+1}) \hat{\beta}_{t+1,i} \quad (24)$$

$$1 \leq i \leq N$$

$$\hat{\beta}_{t,i} = c_t \cdot \ddot{\beta}_{t,i} \quad (25)$$

- Se demonstrează: $\hat{\beta}_{t,i} = c_t \cdot c_{t+1} \cdot \dots \cdot c_T \cdot \beta_{t,i}$



Exemplu de aplicație

- Să reluăm exemplul de mai devreme cu robotul.
- Robotul acționează diferit în fața a 2 tipuri de personalitate:
 - *joivialul*
 - *morocănosul*.
- Pentru fiecare există un set de parametri:
 - $\lambda^1 = (A^1, B^1, \Pi^1)$
 - $\lambda^2 = (A^2, B^2, \Pi^2)$
- Robotul recunoaște următoarele gesturi:
 $(zâmbet \mid rânjet) \longrightarrow (zâmbet \mid rânjet) \longrightarrow \text{încruntare}$
- **Întrebare:** Cărei personalități este mai probabil să-i aparțină cel monitorizat?



Jovialul

Jovialul



s₁:vesel

s₂:trist

s₃:nervos

$$\lambda^1 = (A^1, B^1, \Pi^1)$$


$$A^1 = \begin{matrix} s_1 & s_2 & s_3 \\ s_1 & & \\ s_2 & & \\ s_3 & & \end{matrix}$$

$$\Pi^1 = \begin{pmatrix} s_1 & s_2 & s_3 \end{pmatrix}$$

$$B^1 = \begin{matrix} v_1 & v_2 & v_3 \\ s_1 & & \\ s_2 & & \\ s_3 & & \end{matrix}$$

Jovialul

Jovialul



$$\lambda^1 = (A^1, B^1, \Pi^1)$$


$$A^1 = \begin{matrix} & s_1 & s_2 & s_3 \\ s_1 & 0.8 & 0.1 & 0.1 \\ s_2 & & & \\ s_3 & & & \end{matrix}$$

$$\Pi^1 = \left(\begin{matrix} & s_1 & s_2 & s_3 \\ v_1 & & & \\ v_2 & & & \\ v_3 & & & \end{matrix} \right)$$

$$B^1 = \begin{matrix} & s_1 & s_2 & s_3 \\ s_1 & & & \\ s_2 & & & \\ s_3 & & & \end{matrix}$$

Jovialul

Jovialul



$$\lambda^1 = (A^1, B^1, \Pi^1)$$


$$A^1 = \begin{pmatrix} s_1 & s_2 & s_3 \\ s_1 & 0.8 & 0.1 & 0.1 \\ s_2 & 0.25 & 0.25 & 0.5 \\ s_3 & & & \end{pmatrix}$$

$$\Pi^1 = \left(\begin{array}{ccc} s_1 & s_2 & s_3 \\ v_1 & v_2 & v_3 \end{array} \right)$$

$$B^1 = \begin{pmatrix} s_1 \\ s_2 \\ s_3 \end{pmatrix}$$

Jovialul

Jovialul



$$\lambda^1 = (A^1, B^1, \Pi^1)$$


$$A^1 = \begin{pmatrix} s_1 & s_2 & s_3 \\ s_1 & 0.8 & 0.1 & 0.1 \\ s_2 & 0.25 & 0.25 & 0.5 \\ s_3 & 0.8 & 0.2 & 0 \end{pmatrix}$$

$$\Pi^1 = \left(\begin{array}{ccc} s_1 & s_2 & s_3 \end{array} \right)$$

$$B^1 = \begin{pmatrix} v_1 \\ v_2 \\ v_3 \end{pmatrix}$$

Jovialul

Jovialul



$$\lambda^1 = (A^1, B^1, \Pi^1)$$

$$A^1 = \begin{pmatrix} s_1 & s_2 & s_3 \\ s_1 & 0.8 & 0.1 & 0.1 \\ s_2 & 0.25 & 0.25 & 0.5 \\ s_3 & 0.8 & 0.2 & 0 \end{pmatrix}$$

$$\Pi^1 = \begin{pmatrix} s_1 & s_2 & s_3 \\ 0.7 & 0.2 & 0.1 \end{pmatrix}$$

$$B^1 = \begin{pmatrix} v_1 \\ v_2 \\ v_3 \\ s_1 \\ s_2 \\ s_3 \end{pmatrix}$$



Jovialul

Jovialul



s₁: vesel

s₂: trist

s₃: nervos

v₁: zâmbet
/ rânjet

v₂: nimic

v₃: încruntare

$$\lambda^1 = (A^1, B^1, \Pi^1)$$


$$A^1 = \begin{pmatrix} s_1 & s_2 & s_3 \\ s_1 & 0.8 & 0.1 & 0.1 \\ s_2 & 0.25 & 0.25 & 0.5 \\ s_3 & 0.8 & 0.2 & 0 \end{pmatrix}$$

$$\Pi^1 = \begin{pmatrix} s_1 & s_2 & s_3 \\ 0.7 & 0.2 & 0.1 \end{pmatrix}$$

$$B^1 = \begin{pmatrix} v_1 \\ v_2 \\ v_3 \end{pmatrix}$$

Jovialul

Jovialul



$$\lambda^1 = (A^1, B^1, \Pi^1)$$


$$A^1 = \begin{pmatrix} s_1 & s_2 & s_3 \\ s_1 & 0.8 & 0.1 & 0.1 \\ s_2 & 0.25 & 0.25 & 0.5 \\ s_3 & 0.8 & 0.2 & 0 \end{pmatrix}$$

$$\Pi^1 = \begin{pmatrix} s_1 & s_2 & s_3 \\ 0.7 & 0.2 & 0.1 \end{pmatrix}$$

$$B^1 = \begin{pmatrix} v_1 & v_2 & v_3 \\ s_1 & 0.7 & 0.3 & 0 \\ s_2 & \\ s_3 & \end{pmatrix}$$

Jovialul

Jovialul



$$\lambda^1 = (A^1, B^1, \Pi^1)$$


$$A^1 = \begin{pmatrix} s_1 & s_2 & s_3 \\ s_1 & 0.8 & 0.1 & 0.1 \\ s_2 & 0.25 & 0.25 & 0.5 \\ s_3 & 0.8 & 0.2 & 0 \end{pmatrix}$$

$$\Pi^1 = \begin{pmatrix} s_1 & s_2 & s_3 \\ 0.7 & 0.2 & 0.1 \end{pmatrix}$$

$$B^1 = \begin{pmatrix} v_1 & v_2 & v_3 \\ s_1 & 0.7 & 0.3 & 0 \\ s_2 & 0 & 0.7 & 0.3 \\ s_3 & 0 & 0 & 0 \end{pmatrix}$$

Jovialul

Jovialul



$$\lambda^1 = (A^1, B^1, \Pi^1)$$


$$A^1 = \begin{pmatrix} s_1 & s_2 & s_3 \\ s_1 & 0.8 & 0.1 & 0.1 \\ s_2 & 0.25 & 0.25 & 0.5 \\ s_3 & 0.8 & 0.2 & 0 \end{pmatrix}$$

$$\Pi^1 = \begin{pmatrix} s_1 & s_2 & s_3 \\ 0.7 & 0.2 & 0.1 \end{pmatrix}$$

$$B^1 = \begin{pmatrix} v_1 & v_2 & v_3 \\ s_1 & 0.7 & 0.3 & 0 \\ s_2 & 0 & 0.7 & 0.3 \\ s_3 & 0.6 & 0 & 0.4 \end{pmatrix}$$

Jovialul

Jovialul



$$\lambda^1 = (A^1, B^1, \Pi^1)$$

$$A^1 = \begin{pmatrix} s_1 & s_2 & s_3 \\ s_1 & 0.8 & 0.1 & 0.1 \\ s_2 & 0.25 & 0.25 & 0.5 \\ s_3 & 0.8 & 0.2 & 0 \end{pmatrix}$$

$$\Pi^1 = \begin{pmatrix} s_1 & s_2 & s_3 \\ 0.7 & 0.2 & 0.1 \end{pmatrix}$$

$$B^1 = \begin{pmatrix} v_1 & v_2 & v_3 \\ s_1 & 0.7 & 0.3 & 0 \\ s_2 & 0 & 0.7 & 0.3 \\ s_3 & 0.6 & 0 & 0.4 \end{pmatrix}$$



Morocănosul

Morocănosul



s₁:vesel

s₂:trist

s₃:nervos

$$\lambda^2 = (A^2, B^2, \Pi^2)$$


$$A^2 = \begin{matrix} s_1 & s_2 & s_3 \\ s_1 \\ s_2 \\ s_3 \end{matrix} \left(\begin{array}{c} \\ \\ \\ \end{array} \right)$$

$$\Pi^2 = \begin{matrix} s_1 & s_2 & s_3 \\ (& &) \end{matrix}$$

$$B^2 = \begin{matrix} v_1 & v_2 & v_3 \\ s_1 \\ s_2 \\ s_3 \end{matrix} \left(\begin{array}{c} \\ \\ \\ \end{array} \right)$$

Morocănosul

Morocănosul



$$\lambda^2 = (A^2, B^2, \Pi^2)$$


$$A^2 = \begin{matrix} & s_1 & s_2 & s_3 \\ s_1 & 0.5 & 0.3 & 0.2 \\ s_2 & & & \\ s_3 & & & \end{matrix}$$

$$\Pi^2 = \left(\begin{matrix} & s_1 & s_2 & s_3 \\ v_1 & & & \\ v_2 & & & \\ v_3 & & & \end{matrix} \right)$$

$$B^2 = \begin{matrix} & s_1 & s_2 & s_3 \\ s_1 & & & \\ s_2 & & & \\ s_3 & & & \end{matrix}$$

Morocănosul

Morocănosul



$$\lambda^2 = (A^2, B^2, \Pi^2)$$


$$A^2 = \begin{pmatrix} s_1 & s_2 & s_3 \\ s_1 & 0.5 & 0.3 & 0.2 \\ s_2 & 0.1 & 0.6 & 0.3 \\ s_3 & & & \end{pmatrix}$$

$$\Pi^2 = \left(\begin{array}{ccc} s_1 & s_2 & s_3 \\ & & \end{array} \right)$$

$$B^2 = \begin{pmatrix} s_1 \\ s_2 \\ s_3 \\ v_1 & v_2 & v_3 \end{pmatrix}$$

Morocănosul

Morocănosul



$$\lambda^2 = (A^2, B^2, \Pi^2)$$

$$A^2 = \begin{pmatrix} s_1 & s_2 & s_3 \\ s_1 & 0.5 & 0.3 & 0.2 \\ s_2 & 0.1 & 0.6 & 0.3 \\ s_3 & 0.4 & 0.5 & 0.1 \end{pmatrix}$$


$$\Pi^2 = \left(\begin{array}{ccc} s_1 & s_2 & s_3 \end{array} \right)$$

$$B^2 = \begin{pmatrix} v_1 \\ v_2 \\ v_3 \end{pmatrix}$$

$$s_1 \\ s_2 \\ s_3$$

Morocănosul

Morocănosul



$$\lambda^2 = (A^2, B^2, \Pi^2)$$

$$A^2 = \begin{pmatrix} s_1 & s_2 & s_3 \\ s_1 & 0.5 & 0.3 & 0.2 \\ s_2 & 0.1 & 0.6 & 0.3 \\ s_3 & 0.4 & 0.5 & 0.1 \end{pmatrix}$$

$$\Pi^2 = \begin{pmatrix} s_1 & s_2 & s_3 \\ 0.3 & 0.5 & 0.2 \end{pmatrix}$$

$$B^2 = \begin{pmatrix} v_1 \\ v_2 \\ v_3 \\ s_1 \\ s_2 \\ s_3 \end{pmatrix}$$

Morocănosul

Morocănosul



s₁: vesel

s₂: trist

s₃: nervos

v₁: zâmbet / rânger

v₂: nimic

v₃: încruntare

$$\lambda^2 = (A^2, B^2, \Pi^2)$$


$$A^2 = \begin{pmatrix} s_1 & s_2 & s_3 \\ s_1 & 0.5 & 0.3 & 0.2 \\ s_2 & 0.1 & 0.6 & 0.3 \\ s_3 & 0.4 & 0.5 & 0.1 \end{pmatrix}$$

$$\Pi^2 = \begin{pmatrix} s_1 & s_2 & s_3 \\ 0.3 & 0.5 & 0.2 \end{pmatrix}$$

$$B^2 = \begin{pmatrix} v_1 \\ v_2 \\ v_3 \end{pmatrix}$$

Morocănosul

Morocănosul



$$\lambda^2 = (A^2, B^2, \Pi^2)$$


$$A^2 = \begin{pmatrix} s_1 & s_2 & s_3 \\ s_1 & 0.5 & 0.3 & 0.2 \\ s_2 & 0.1 & 0.6 & 0.3 \\ s_3 & 0.4 & 0.5 & 0.1 \end{pmatrix}$$

$$\Pi^2 = \begin{pmatrix} s_1 & s_2 & s_3 \\ 0.3 & 0.5 & 0.2 \end{pmatrix}$$

$$B^2 = \begin{pmatrix} v_1 & v_2 & v_3 \\ s_1 & 0.4 & 0.5 & 0.1 \\ s_2 & \\ s_3 & \end{pmatrix}$$

Morocănosul

Morocănosul



$$\lambda^2 = (A^2, B^2, \Pi^2)$$


$$A^2 = \begin{pmatrix} s_1 & s_2 & s_3 \\ s_1 & 0.5 & 0.3 & 0.2 \\ s_2 & 0.1 & 0.6 & 0.3 \\ s_3 & 0.4 & 0.5 & 0.1 \end{pmatrix}$$

$$\Pi^2 = \begin{pmatrix} s_1 & s_2 & s_3 \\ 0.3 & 0.5 & 0.2 \end{pmatrix}$$

$$B^2 = \begin{pmatrix} v_1 & v_2 & v_3 \\ s_1 & 0.4 & 0.5 & 0.1 \\ s_2 & 0 & 0.2 & 0.8 \\ s_3 & \dots & \dots & \dots \end{pmatrix}$$

Morocănosul

Morocănosul



$$\lambda^2 = (A^2, B^2, \Pi^2)$$


$$A^2 = \begin{pmatrix} s_1 & s_2 & s_3 \\ s_1 & 0.5 & 0.3 & 0.2 \\ s_2 & 0.1 & 0.6 & 0.3 \\ s_3 & 0.4 & 0.5 & 0.1 \end{pmatrix}$$

$$\Pi^2 = \begin{pmatrix} s_1 & s_2 & s_3 \\ 0.3 & 0.5 & 0.2 \end{pmatrix}$$

$$B^2 = \begin{pmatrix} v_1 & v_2 & v_3 \\ s_1 & 0.4 & 0.5 & 0.1 \\ s_2 & 0 & 0.2 & 0.8 \\ s_3 & 0.6 & 0 & 0.4 \end{pmatrix}$$

Morocănosul

Morocănosul




$$\lambda^2 = (A^2, B^2, \Pi^2)$$

$$A^2 = \begin{pmatrix} s_1 & s_2 & s_3 \\ s_1 & 0.5 & 0.3 & 0.2 \\ s_2 & 0.1 & 0.6 & 0.3 \\ s_3 & 0.4 & 0.5 & 0.1 \end{pmatrix}$$

$$\Pi^2 = \begin{pmatrix} s_1 & s_2 & s_3 \\ 0.3 & 0.5 & 0.2 \end{pmatrix}$$


$$B^2 = \begin{pmatrix} v_1 & v_2 & v_3 \\ s_1 & 0.4 & 0.5 & 0.1 \\ s_2 & 0 & 0.2 & 0.8 \\ s_3 & 0.6 & 0 & 0.4 \end{pmatrix}$$

Calculul variabilelor α :



$$\hat{\alpha} = \left[\quad \right] c = \left[\quad \right]$$


Calculul variabilelor α :



$$\ddot{\alpha}_{1,1} = \pi_{1,1} \cdot b_1(v_1) = 0.7 \cdot 0.7 = 0.49$$

$$\hat{\alpha} = \left[\quad \right] \quad c = \left[\quad \right]$$

Calculul variabilelor α :




$$\ddot{\alpha}_{1,1} = \pi_{1,1} \cdot b_1(v_1) = 0.7 \cdot 0.7 = 0.49$$

$$\ddot{\alpha}_{1,2} = \pi_{1,2} \cdot b_2(v_1) = 0.2 \cdot 0 = 0$$

$$\hat{\alpha} = \left[\quad \right] c = \left[\quad \right]$$


Calculul variabilelor α :



$$\hat{\alpha} = \left[\quad \right] c = \left[\quad \right]$$



Calculul variabilelor α :



$$\ddot{\alpha}_{1,1} = \pi_{1,1} \cdot b_1(v_1) = 0.7 \cdot 0.7 = 0.49$$

$$\ddot{\alpha}_{1,2} = \pi_{1,2} \cdot b_2(v_1) = 0.2 \cdot 0 = 0$$


$$\ddot{\alpha}_{1,3} = \pi_{1,3} \cdot b_3(v_1) = 0.1 \cdot 0.6 = 0.6$$

$$c_1 = \frac{1}{\ddot{\alpha}_{1,1} + \ddot{\alpha}_{1,2} + \ddot{\alpha}_{1,3}}$$

$$c_1 = 1/0.54 \approx 1.8182$$

$$\hat{\alpha} = \left[\begin{array}{c} \\ \\ \\ \end{array} \right] \quad c = \left[\begin{array}{c} 1.8182 \\ \\ \\ \end{array} \right]$$

Calculul variabilelor α :



$$\ddot{\alpha}_{1,1} = \pi_{1,1} \cdot b_1(v_1) = 0.7 \cdot 0.7 = 0.49$$

$$\ddot{\alpha}_{1,2} = \pi_{1,2} \cdot b_2(v_1) = 0.2 \cdot 0 = 0$$

$$\ddot{\alpha}_{1,3} = \pi_{1,3} \cdot b_3(v_1) = 0.1 \cdot 0.6 = 0.6$$

$$c_1 = \frac{1}{\ddot{\alpha}_{1,1} + \ddot{\alpha}_{1,2} + \ddot{\alpha}_{1,3}}$$

$$c_1 = 1/0.54 \approx 1.8182$$


$$\hat{\alpha} = \begin{bmatrix} 0.8909 & 0 & 0.1091 \end{bmatrix} \quad c = \begin{bmatrix} 1.8182 \end{bmatrix}$$

$$\hat{\alpha}_{1,1} = c_1 \cdot \ddot{\alpha}_{1,1} = 0.8909$$

$$\hat{\alpha}_{1,2} = c_1 \cdot \ddot{\alpha}_{1,2} = 0$$

$$\hat{\alpha}_{1,3} = c_1 \cdot \ddot{\alpha}_{1,3} = 0.1091$$

Calculul variabilelor α :




$$\ddot{\alpha}_{2,1} = b_1(v_1) \sum \hat{\alpha}_{1,i} a_{i,1}$$

$$= \dots = 0.56$$

$$\hat{\alpha} = \begin{bmatrix} 0.8909 & 0 & 0.1091 \end{bmatrix} \quad c = \begin{bmatrix} 1.8182 \end{bmatrix}$$

Calculul variabilelor α :




$$\ddot{\alpha}_{2,1} = b_1(v_1) \sum \hat{\alpha}_{1,i} a_{i,1} \\ = \dots = 0.56$$

$$\ddot{\alpha}_{2,2} = b_2(v_1) \sum \hat{\alpha}_{1,i} a_{i,2} = 0$$

$$\hat{\alpha} = \begin{bmatrix} 0.8909 & 0 & 0.1091 \end{bmatrix} \quad c = \begin{bmatrix} 1.8182 \end{bmatrix}$$



Calculul variabilelor α :



$$\ddot{\alpha}_{2,1} = b_1(v_1) \sum \hat{\alpha}_{1,i} a_{i,1} \\ = \dots = 0.56$$


$$\ddot{\alpha}_{2,2} = b_2(v_1) \sum \hat{\alpha}_{1,i} a_{i,2} = 0$$

$$\ddot{\alpha}_{2,3} = b_3(v_1) \sum \hat{\alpha}_{1,i} a_{i,3} = 0.0535$$

$$\hat{\alpha} = \begin{bmatrix} 0.8909 & 0 & 0.1091 \end{bmatrix} \quad c = \begin{bmatrix} 1.8182 \end{bmatrix}$$



Calculul variabilelor α :



$$\ddot{\alpha}_{2,1} = b_1(v_1) \sum \hat{\alpha}_{1,i} a_{i,1} \\ = \dots = 0.56$$

$$\ddot{\alpha}_{2,2} = b_2(v_1) \sum \hat{\alpha}_{1,i} a_{i,2} = 0$$

$$\ddot{\alpha}_{2,3} = b_3(v_1) \sum \hat{\alpha}_{1,i} a_{i,3} = 0.0535$$


$$c_2 = \frac{1}{\ddot{\alpha}_{2,1} + \ddot{\alpha}_{2,2} + \ddot{\alpha}_{2,3}}$$

$$c_2 = \frac{1}{0.484 + 0.0776 + 0} = 1.63$$

$$\hat{\alpha} = \begin{bmatrix} 0.8909 & 0 & 0.1091 \end{bmatrix} \quad c = \begin{bmatrix} 1.8182 \\ 1.63 \end{bmatrix}$$



Calculul variabilelor α :



$$\ddot{\alpha}_{2,1} = b_1(v_1) \sum \hat{\alpha}_{1,i} a_{i,1} \\ = \dots = 0.56$$

$$\ddot{\alpha}_{2,2} = b_2(v_1) \sum \hat{\alpha}_{1,i} a_{i,2} = 0$$

$$\ddot{\alpha}_{2,3} = b_3(v_1) \sum \hat{\alpha}_{1,i} a_{i,3} = 0.0535$$

$$c_2 = \frac{1}{\ddot{\alpha}_{2,1} + \ddot{\alpha}_{2,2} + \ddot{\alpha}_{2,3}}$$

$$c_2 = \frac{1}{0.484 + 0.0776 + 0} = 1.63$$


$$\hat{\alpha}_{2,1} = c_2 \cdot \ddot{\alpha}_{2,1} = 0.9128$$

$$\hat{\alpha}_{2,2} = c_2 \cdot \ddot{\alpha}_{2,2} = 0$$

$$\hat{\alpha}_{2,3} = c_2 \cdot \ddot{\alpha}_{2,3} = 0.0872$$

$$\hat{\alpha} = \begin{bmatrix} 0.8909 & 0 & 0.1091 \\ 0.9128 & 0 & 0.0872 \end{bmatrix} \quad c = \begin{bmatrix} 1.8182 \\ 1.63 \end{bmatrix}$$


Calculul variabilelor α :



$$\begin{aligned}\ddot{\alpha}_{3,1} &= b_1(v_3) \sum \hat{\alpha}_{2,i} a_{i,1} \\ &= \dots = 0\end{aligned}$$

$$\hat{\alpha} = \begin{bmatrix} 0.8909 & 0 & 0.1091 \\ 0.9128 & 0 & 0.0872 \end{bmatrix} \quad c = \begin{bmatrix} 1.8182 \\ 1.63 \end{bmatrix}$$

Calculul variabilelor α :




$$\ddot{\alpha}_{3,1} = b_1(v_3) \sum \hat{\alpha}_{2,i} a_{i,1} \\ = \dots = 0$$

$$\ddot{\alpha}_{3,2} = b_2(v_3) \sum \hat{\alpha}_{2,i} a_{i,2} = 0.0326$$

$$\hat{\alpha} = \begin{bmatrix} 0.8909 & 0 & 0.1091 \\ 0.9128 & 0 & 0.0872 \end{bmatrix} \quad c = \begin{bmatrix} 1.8182 \\ 1.63 \end{bmatrix}$$



Calculul variabilelor α :



$$\ddot{\alpha}_{3,1} = b_1(v_3) \sum \hat{\alpha}_{2,i} a_{i,1} = \dots = 0$$


$$\ddot{\alpha}_{3,2} = b_2(v_3) \sum \hat{\alpha}_{2,i} a_{i,2} = 0.0326$$

$$\ddot{\alpha}_{3,3} = b_3(v_3) \sum \hat{\alpha}_{2,i} a_{i,3} = 0.0365$$

$$\hat{\alpha} = \begin{bmatrix} 0.8909 & 0 & 0.1091 \\ 0.9128 & 0 & 0.0872 \end{bmatrix} \quad c = \begin{bmatrix} 1.8182 \\ 1.63 \end{bmatrix}$$



Calculul variabilelor α :



$$\begin{aligned}\ddot{\alpha}_{3,1} &= b_1(v_3) \sum \hat{\alpha}_{2,i} a_{i,1} \\ &= \dots = 0\end{aligned}$$

$$\ddot{\alpha}_{3,2} = b_2(v_3) \sum \hat{\alpha}_{2,i} a_{i,2} = 0.0326$$

$$\ddot{\alpha}_{3,3} = b_3(v_3) \sum \hat{\alpha}_{2,i} a_{i,3} = 0.0365$$


$$c_3 = \frac{1}{\ddot{\alpha}_{3,1} + \ddot{\alpha}_{3,2} + \ddot{\alpha}_{3,3}}$$

$$c_3 = \frac{1}{x} = 14.4718$$

$$\hat{\alpha} = \begin{bmatrix} 0.8909 & 0 & 0.1091 \\ 0.9128 & 0 & 0.0872 \end{bmatrix} \quad c = \begin{bmatrix} 1.8182 \\ 1.63 \\ 14.4718 \end{bmatrix}$$



Calculul variabilelor α :



$$\ddot{\alpha}_{3,1} = b_1(v_3) \sum \hat{\alpha}_{2,i} a_{i,1} \\ = \dots = 0$$

$$\ddot{\alpha}_{3,2} = b_2(v_3) \sum \hat{\alpha}_{2,i} a_{i,2} = 0.0326$$

$$\ddot{\alpha}_{3,3} = b_3(v_3) \sum \hat{\alpha}_{2,i} a_{i,3} = 0.0365$$

$$c_3 = \frac{1}{\ddot{\alpha}_{3,1} + \ddot{\alpha}_{3,2} + \ddot{\alpha}_{3,3}}$$

$$c_3 = \frac{1}{x} = 14.4718$$

$$\hat{\alpha}_{3,1} = c_3 \cdot \ddot{\alpha}_{3,1} = 0$$

$$\hat{\alpha}_{3,2} = c_3 \cdot \ddot{\alpha}_{3,2} = 0.4718$$

$$\hat{\alpha}_{3,3} = c_3 \cdot \ddot{\alpha}_{3,3} = 0.5282$$

$$\hat{\alpha} = \begin{bmatrix} 0.8909 & 0 & 0.1091 \\ 0.9128 & 0 & 0.0872 \\ 0 & 0.4718 & 0.5282 \end{bmatrix} \quad c = \begin{bmatrix} 1.8182 \\ 1.63 \\ 14.4718 \end{bmatrix}$$



Morocănos sau jovial?

- $c = [1.8182 \quad 1.63 \quad 14.4718]$
- Probabilitatea ca sevența observată să fi fost generată de un *jovial*:
 $\log(P(O|\lambda^1)) = - \sum \log(c_i) = -3.7583$



Morocănos sau jovial?

- $c = [1.8182 \quad 1.63 \quad 14.4718]$
- Probabilitatea ca sevența observată să fi fost generată de un *jovial*:
 $\log(P(O|\lambda^1)) = -\sum \log(c_i) = -3.7583$
- Probabilitatea ca sevența observată să fi fost generată de un *morocănos*:
 $\log(P(O|\lambda^2)) = -3.6362$
- $\log(P(O|\lambda^2)) > \log(P(O|\lambda^1))$
- Este mai probabil să avem de-aface cu...


Morocănos sau jovial?

- $c = [1.8182 \quad 1.63 \quad 14.4718]$
- Probabilitatea ca sevența observată să fi fost generată de un *jovial*:
 $\log(P(O|\lambda^1)) = -\sum \log(c_i) = -3.7583$
- Probabilitatea ca sevența observată să fi fost generată de un *morocănos*:
 $\log(P(O|\lambda^2)) = -3.6362$
- $\log(P(O|\lambda^2)) > \log(P(O|\lambda^1))$
- Este mai probabil să avem de-aface cu...


Morocănos




Calculul variabilelor β :




Calculul variabilelor β :




Calculul variabilelor β :




Calculul variabilelor β :




Calculul variabilelor β :




Calculul variabilelor β :




Calculul variabilelor β :




Calculul variabilelor β :



Calculul variabilelor β :



Calculul variabilelor β :





Algoritmul Forward-Backward

Algoritmul 1 Calculul variabilelor α

```

for  $i = 1$  to  $N$  do
2:    $\ddot{\alpha}_{1,i} \leftarrow \pi_i \cdot b_i(o_1)$ 
end for
4:    $c_1 \leftarrow \left( \sum_{i=1}^N \ddot{\alpha}_{1,i} \right)^{-1}$ 
for  $i = 1$  to  $N$  do
6:    $\hat{\alpha}_{1,i} \leftarrow c_1 \cdot \ddot{\alpha}_{1,i}$ 
end for
8: for  $t = 1$  to  $T - 1$  do
      for  $i = 1$  to  $N$  do
10:     $\ddot{\alpha}_{t+1,i} \leftarrow \left[ \sum_{i=1}^N \hat{\alpha}_{t,i} a_{i,j} \right] b_j(o_{t+1})$ 
      end for
12:     $c_{t+1} \leftarrow \left( \sum_{i=1}^N \ddot{\alpha}_{t+1,i} \right)^{-1}$ 
      for  $i = 1$  to  $N$  do
14:         $\hat{\alpha}_{t+1,i} \leftarrow c_{t+1} \cdot \ddot{\alpha}_{t+1,i}$ 
      end for
16: end for

```

Algoritmul 2 Calculul $P(O|\lambda)$

$$\log P \leftarrow - \sum_{t=1}^T c_t$$

Algoritmul 3 Calculul variabilelor β

```

for  $i = 1$  to  $N$  do
2:    $\hat{\beta}_{T,i} \leftarrow c_T$ 
end for
4: for  $t = (T - 1)$  to  $1$  do
      for  $i = 1$  to  $N$  do
6:         $\hat{\beta}_{t,i} \leftarrow \sum_{j=1}^N a_{i,j} b_j(o_{t+1}) \hat{\beta}_{t+1,j} \cdot c_t$ 
      end for
8: end for

```



A venit vremea să scriem cod

- 1 Faceți o copie a fișierului `forward_backward_disc.m.stub` și denumiți-o `forward_backward_disc.m` (eliminați sufixul `.stub`). Veți implementa funcția:

```
function [logP, Alpha, Beta, Scale] = ...
forward_backward_disc(O,Pi, A, B)
```



A venit vremea să scriem cod

- ① Faceți o copie a fișierului `forward_backward_disc.m.stub` și denumiți-o `forward_backward_disc.m` (eliminați sufixul `.stub`). Veți implementa funcția:

```
function [logP, Alpha, Beta, Scale] = ...
forward_backward_disc(O,Pi, A, B)
```

- ② Completați cele trei secțiuni.

```
1 ...
2 Scale = zeros (1, T); % Scale is an 1 x T matrix
3 Alpha = zeros (T, N); % Alpha is a T x N matrix
4 Beta = ones (T, N); % Beta is a T x N matrix
5 %% Forward variables
6 % alpha_disc_start - Write code below
7
8 % alpha_disc_end - Write code above
9 ...
```

- ③ Folosiți `hmm_test` pentru a vă testa codul.



Outline

1 Aplicații în Învățarea Automată pentru MMA

- Învățarea Automată
- MMA în Învățarea Automată

2 Teoria MMA

- Cele Trei Probleme ale MMA
- Fundamente Matematice

3 Implementarea MMA

- Problema Evaluării: Algoritmul Forward-Backward
- **Problema Interpretării: Algoritmul Viterbi**
- Problema Estimării: Algoritmul Baum-Welch

4 Demo: Recunoașterea Simbolurilor

5 Tipuri de MMA

6 Discuții și Concluzii



Problema interpretării

Problema interpretării unei secvențe de observații

Date fiind un model $\lambda = (A, B, \Pi)$ și o secvență de observații $O = [o_1 o_2 \cdots o_T]$, cum alegem o secvență corespunzătoare de stări $Q_{\text{best}} = [q_{1_{\text{best}}} q_{2_{\text{best}}} \cdots q_{T_{\text{best}}}]$ care să dea un înțeles observațiilor? Cum descoperim partea ascunsă a modelului?



Problema interpretării

Problema interpretării unei secvențe de observații

Date fiind un model $\lambda = (A, B, \Pi)$ și o secvență de observații $O = [o_1 o_2 \cdots o_T]$, cum alegem o secvență corespunzătoare de stări $Q_{\text{best}} = [q_{1_{\text{best}}} q_{2_{\text{best}}} \cdots q_{T_{\text{best}}}]$ care să dea un înțeles observațiilor? Cum descoperim partea ascunsă a modelului?

- Răspunsul depinde de criteriul cu care alegem *cea mai bună* secvență



Problema interpretării

Problema interpretării unei secvențe de observații

Date fiind un model $\lambda = (A, B, \Pi)$ și o secvență de observații $O = [o_1 o_2 \cdots o_T]$, cum alegem o secvență corespunzătoare de stări $Q_{\text{best}} = [q_{1_{\text{best}}} q_{2_{\text{best}}} \cdots q_{T_{\text{best}}}]$ care să dea un înțeles observațiilor? Cum descoperim partea ascunsă a modelului?

- Răspunsul depinde de criteriul cu care alegem *cea mai bună* secvență
 - **secvența celor mai probabile stări** $q_{t_{\text{best}}}$ (luate individual), date fiind modelul și secvența observată:

$$q_{t_{\text{best}}} = \underset{s_i}{\operatorname{argmax}} P(q_t = s_i | O, \lambda)$$
 - **cea mai probabilă secvență de stări** Q (per ansamblu), date fiind modelul și secvența observată:

$$Q_{\text{best}} = \underset{\text{all } Q}{\operatorname{argmax}} P(Q | O, \lambda)$$



Secvența celor mai probabile stări

Notăție: $P(q_t = s_i | O, \lambda) = \gamma_{t,i} = \frac{\alpha_{t,i}\beta_{t,i}}{\sum_{j=1}^N \alpha_{t,j}\beta_{t,j}}$

- Este un criteriu satisfăcător?



Secvența celor mai probabile stări

Notăție: $P(q_t = s_i | O, \lambda) = \gamma_{t,i} = \frac{\alpha_{t,i}\beta_{t,i}}{\sum_{j=1}^N \alpha_{t,j}\beta_{t,j}}$

- Este un criteriu satisfăcător?
- **NU!**

Pot exista q_t și q_{t+1} astfel încât $a_{q_t, q_{t+1}} = 0$



Algoritmul Viterbi

- Criteriu care ia în considerare distribuțiile de probabilitate ale tranzițiilor între stări
- Cea mai bună cale: $Q_{\text{best}} = [q_{1_{\text{best}}} q_{2_{\text{best}}} \cdots q_{T_{\text{best}}}]$

$$Q_{\text{best}} = \underset{Q}{\operatorname{argmax}} P(Q|O, \lambda) = \underset{Q}{\operatorname{argmax}} P(Q, O|\lambda) \quad (6)$$

- **Algoritmul Viterbi** - programare dinamică
- Vom introduce variabilele *delta*.



Variabilele δ - intuiție

Întrebare

Dacă $Q = [q_1, q_2, \dots, q_{t-1}, q_t]$ este cea mai bună secvență care explică $O = [o_1, o_2, \dots, o_{t-1}, o_t]$, atunci putem afirma că $Q[1 : t - 1]$ este cea mai bună secvență de stări care explică $O[1 : t - 1]$?



Variabilele δ - intuiție

Întrebare

Dacă $Q = [q_1, q_2, \dots, q_{t-1}, q_t]$ este cea mai bună secvență care explică $O = [o_1, o_2, \dots, o_{t-1}, o_t]$, atunci putem afirma că $Q[1 : t - 1]$ este cea mai bună secvență de stări care explică $O[1 : t - 1]$?

- NU!

$$\begin{aligned} P(q_1 = s_{i_1}, q_2 = s_{i_2}, \dots, q_{t-1} = s_{i_{t-1}}, q_t = s_{i_t} | O, \lambda) = \\ P(q_1, q_2, \dots, q_{t-1} | O, \lambda) \cdot P(q_t = s_{i_t} | q_{t-1} = s_{i_{t-1}}, \lambda) \cdot P(o_t | q_t = s_{i_t}, \lambda) \end{aligned}$$



Variabilele δ

- Vom numi variabile δ :

$$\delta_{t,i} = \max_{q_1, \dots, q_{t-1}} P([q_1 q_2 \dots q_{t-1} s_i], [o_1, o_2, \dots, o_t] | \lambda) \quad (26)$$

- $\delta_{t,i}$ - cea mai mare probabilitate a unei secvențe de stări de lungime t care ajunge în s_i și explică primele t valori observate


Variabilele δ

- Vom numi variabile δ :

$$\delta_{t,i} = \max_{q_1, \dots, q_{t-1}} P([q_1 q_2 \dots q_{t-1} s_i], [o_1, o_2, \dots, o_t] | \lambda) \quad (26)$$

- $\delta_{t,i}$ - cea mai mare probabilitate a unei secvențe de stări de lungime t care ajunge în s_i și explică primele t valori observate
- relația dintre variabilele δ :

$$\delta_{t+1,j} = [\max_i \delta_{t,i} \cdot a_{i,j}] \cdot b_j(o_{t+1}) \quad (27)$$





Algoritmul Viterbi - Privire de ansamblu

Pași înainte

Calculăm cea mai mare probabilitate de a ajunge în starea s_i la momentul t pe baza celor mai mari probabilități de a fi ajuns în toate stările s_j la $t - 1$.



Algoritmul Viterbi - Privire de ansamblu

Pași înainte

Calculăm cea mai mare probabilitate de a ajunge în starea s_i la momentul t pe baza celor mai mari probabilități de a fi ajuns în toate stările s_j la $t - 1$.

La final ($t = T$)

Starea finală este acea stare s_i cu cea mai mare probabilitate de a ajunge la ea după observarea tuturor valorilor.



Algoritmul Viterbi - Privire de ansamblu

Pași înainte

Calculăm cea mai mare probabilitate de a ajunge în starea s_i la momentul t pe baza celor mai mari probabilități de a fi ajuns în toate stările s_j la $t - 1$.

La final ($t = T$)

Starea finală este acea stare s_i cu cea mai mare probabilitate de a ajunge la ea după observarea tuturor valorilor.

Pași înapoi

Refacem *cea mai bună cale* alegând pentru fiecare moment t starea care a dus la probabilitatea maximă pentru starea de la $t + 1$.



Algoritmul Viterbi (I)

1 Inițializare:

$$\begin{aligned}\delta_{1,i} &= \pi_i b_i(o_1), \quad 1 \leq i \leq N \\ \psi_{1,i} &= 0\end{aligned}\tag{28}$$

2 Recursivitate:

$$\begin{aligned}\delta_{t,j} &= [\max_i \delta_{t-1,i} \cdot a_{i,j}] \cdot b_j(o_t) \quad 2 \leq t \leq T, 1 \leq j \leq N \\ \psi_{t,i} &= \operatorname{argmax}_i \delta_{t-1,i} \cdot a_{i,j} \quad 2 \leq t \leq T, 1 \leq j \leq N\end{aligned}\tag{29}$$



Algoritmul Viterbi (II)

3 Terminare:

$$\begin{aligned} P(Q_{\text{best}} | O, \lambda) &= \max_i \delta_{T,i} \\ q_{T_{\text{best}}} &= \operatorname{argmax}_i \delta_{T,i} \end{aligned} \tag{30}$$

4 Backtracking:

$$q_{t_{\text{best}}} = \psi_{t+1}(q_{t+1_{\text{best}}}), \quad t=T-1, T-2, \dots, 1 \tag{31}$$



Probleme numerice

- Cine este $P(Q_{\text{best}}|O, \lambda)$?

$$P(Q_{\text{best}}|O, \lambda) = \delta_{T,i_T}$$

$$P(Q_{\text{best}}|O, \lambda) = \delta_{T-1,i_{T-1}} \cdot a_{i_{T-1},i_T} \cdot b_T(o_T)$$

$$P(Q_{\text{best}}|O, \lambda) = \delta_{T-2,i_{T-2}} \cdot a_{i_{T-2},i_{T-1}} \cdot b_{T-1}(o_{T-1}) \cdot a_{i_{T-1},j_T} \cdot b_T(o_T)$$

$$P(Q_{\text{best}}|O, \lambda) = \prod \dots$$

- Cum putem evita apropierea rapidă de zero?



Probleme numerice

- Cine este $P(Q_{\text{best}}|O, \lambda)$?

$$P(Q_{\text{best}}|O, \lambda) = \delta_{T,i_T}$$

$$P(Q_{\text{best}}|O, \lambda) = \delta_{T-1,i_{T-1}} \cdot a_{i_{T-1},i_T} \cdot b_T(o_T)$$

$$P(Q_{\text{best}}|O, \lambda) = \delta_{T-2,i_{T-2}} \cdot a_{i_{T-2},i_{T-1}} \cdot b_{T-1}(o_{T-1}) \cdot a_{i_{T-1},i_T} \cdot b_T(o_T)$$

$$P(Q_{\text{best}}|O, \lambda) = \prod \dots$$

- Cum putem evita apropierea rapidă de zero?
- Calculăm $\log(P)$

$$\log(P(Q_{\text{best}}|O, \lambda)) = \log(\delta_{T,i_T})$$

$$\log(P(Q_{\text{best}}|O, \lambda)) = \log(\delta_{T-1,i_{T-1}}) + \log(a_{i_{T-1},i_T}) + \log(b_T(o_T))$$

$$\log(P(Q_{\text{best}}|O, \lambda)) = \log(\delta_{T-2,i_{T-2}}) + \log(a_{i_{T-2},i_{T-1}}) + \log(b_{T-1}(o_{T-1}))$$

$$\log(P(Q_{\text{best}}|O, \lambda)) = \sum \dots$$



Probleme numerice - Rezolvare

- Notație:

$$\phi_{t,i} = \max_{q_1, \dots, q_{t-1}} \log(P(q_1, \dots, q_{t-1}, q_t = s_i, o_1, \dots, o_t | \lambda)) = \log(\delta_{t,i})$$

- Matricele $\log(\Pi)$, $\log(A)$ și $\log(B)$ pot fi precalculate.



Algoritmul Viterbi - $\log(P)$ (I)

1 Inițializare:

$$\begin{aligned}\phi_{1,i} &= \log(\pi_i) + \log(b_i(o_1)), \quad 1 \leq i \leq N \\ \psi_{1,i} &= 0\end{aligned}\tag{32}$$

2 Recursivitate:

$$\begin{aligned}\phi_{t,j} &= [\max_i \phi_{t-1,i} + \log(a_{i,j})] + \log(b_j(o_t)) \quad 2 \leq t \leq T, 1 \leq j \leq N \\ \psi_{t,i} &= \operatorname{argmax}_i \phi_{t-1,i} + \log(a_{i,j}) \quad 2 \leq t \leq T, 1 \leq j \leq N\end{aligned}\tag{33}$$



Algoritmul Viterbi - $\log(P)$ (II)

3 Terminare:

$$\begin{aligned}\log(P(Q_{\text{best}}|O, \lambda)) &= \max_i \phi_{T,i} \\ q_{T_{\text{best}}} &= \operatorname{argmax}_i \phi_{T,i}\end{aligned}\tag{34}$$

4 Backtracking:

$$q_{t_{\text{best}}} = \psi_{t+1}(q_{t+1_{\text{best}}}), \quad t=T-1, T-2, \dots, 1\tag{35}$$



Înapoi la exemplu


- Să reluăm exemplul cu robotul.
- Robotul a recunoscut secvența de gesturi:
 $(zâmbet \mid rânjet) \longrightarrow (zâmbet \mid rânjet) \longrightarrow \text{încruntare}$
- Am stabilit: $P(O|\lambda^1) > P(O|\lambda^2)$



Înapoi la exemplu


- Să reluăm exemplul cu robotul.
- Robotul a recunoscut secvența de gesturi:
(zâmbet | rânjet) → (zâmbet | rânjet) → încruntare
- Am stabilit: $P(O|\lambda^1) > P(O|\lambda^2)$
Deci, robotul se confruntă [, probabil] cu un morocănos!
- A doua întrebare: **Prin ce stări a trecut acesta?**

Jovialul



$$\Phi = \left[\quad \right] \quad \Psi = \left[\quad \right] \quad Q_{best} = [\quad]$$

Jovialul




$$\phi_{1,1} = \log(\pi_1) + \log(b_{1,1})$$

$$\psi_{1,1} = 0$$

$$\Phi = \begin{bmatrix} -2.1202 \\ \vdots \end{bmatrix} \quad \Psi = \begin{bmatrix} 0 \\ \vdots \end{bmatrix} \quad Q_{best} = [\quad]$$

Jovialul




$$\phi_{1,2} = \log(\pi_2) + \log(b_{2,1})$$

$$\psi_{1,2} = 0$$


$$\Phi = \begin{bmatrix} -2.1202 & -\text{Inf} \end{bmatrix} \quad \Psi = \begin{bmatrix} 0 & 0 \end{bmatrix} \quad Q_{best} = []$$

Jovialul



$$\Phi = \begin{bmatrix} -2.1202 & -\text{Inf} & -2.1202 \end{bmatrix} \quad \Psi = \begin{bmatrix} 0 & 0 & 0 \end{bmatrix} \quad Q_{best} = []$$


Jovialul



$$\phi_{1,3} = \max \left\{ \begin{array}{l} \log(\phi_{1,1}) + \log(a_{1,1}), \\ \log(\phi_{2,1}) + \log(a_{2,1}), \\ \log(\phi_{1,3}) + \log(a_{3,1}) \end{array} \right\} + \log(b_{1,1})$$


$$\Phi = \begin{bmatrix} -2.1202 & -Inf & -2.1202 \\ -3.7297 & & \end{bmatrix} \quad \Psi = \begin{bmatrix} 0 & 0 & 0 \end{bmatrix} \quad Q_{best} = [\quad]$$

Jovialul




$$\Phi = \begin{bmatrix} -2.1202 & -\text{Inf} & -2.1202 \\ -3.7297 & & \end{bmatrix} \quad \Psi = \begin{bmatrix} 0 & 0 & 0 \\ 1 & & \end{bmatrix} \quad Q_{best} = []$$

Jovialul




$$\Phi = \begin{bmatrix} -2.1202 & -\text{Inf} & -2.1202 \\ -3.7297 & -\text{Inf} & \end{bmatrix} \quad \Psi = \begin{bmatrix} 0 & 0 & 0 \\ 1 & \end{bmatrix} \quad Q_{best} = []$$

Jovialul




$$\Phi = \begin{bmatrix} -2.1202 & -\text{Inf} & -2.1202 \\ -3.7297 & -\text{Inf} & \end{bmatrix} \quad \Psi = \begin{bmatrix} 0 & 0 & 0 \\ 1 & 3 & \end{bmatrix} \quad Q_{best} = []$$

Jovialul




$$\Phi = \begin{bmatrix} -2.1202 & -Inf & -2.1202 \\ -3.7297 & -Inf & -4.2205 \end{bmatrix} \quad \Psi = \begin{bmatrix} 0 & 0 & 0 \\ 1 & 3 & 0 \end{bmatrix} \quad Q_{best} = []$$

Jovialul




$$\Phi = \begin{bmatrix} -2.1202 & -Inf & -2.1202 \\ -3.7297 & -Inf & -4.2205 \end{bmatrix} \quad \Psi = \begin{bmatrix} 0 & 0 & 0 \\ 1 & 3 & 1 \end{bmatrix} \quad Q_{best} = []$$

Jovialul




$$\Phi = \begin{bmatrix} -2.1202 & -\text{Inf} & -2.1202 \\ -3.7297 & -\text{Inf} & -4.2205 \\ -6.7254 & & \end{bmatrix} \quad \Psi = \begin{bmatrix} 0 & 0 & 0 \\ 1 & 3 & 1 \end{bmatrix} \quad Q_{best} = []$$

Jovialul




$$\Phi = \begin{bmatrix} -2.1202 & -Inf & -2.1202 \\ -3.7297 & -Inf & -4.2205 \\ -6.7254 & & \end{bmatrix} \quad \Psi = \begin{bmatrix} 0 & 0 & 0 \\ 1 & 3 & 1 \\ 1 & & \end{bmatrix} \quad Q_{best} = []$$

Jovialul




$$\Phi = \begin{bmatrix} -2.1202 & -Inf & -2.1202 \\ -3.7297 & -Inf & -4.2205 \\ -6.7254 & -5.1567 \end{bmatrix} \quad \Psi = \begin{bmatrix} 0 & 0 & 0 \\ 1 & 3 & 1 \\ 1 \end{bmatrix} \quad Q_{best} = []$$

Jovialul




$$\Phi = \begin{bmatrix} -2.1202 & -\text{Inf} & -2.1202 \\ -3.7297 & -\text{Inf} & -4.2205 \\ -6.7254 & -5.1567 \end{bmatrix} \quad \Psi = \begin{bmatrix} 0 & 0 & 0 \\ 1 & 3 & 1 \\ 1 & 3 \end{bmatrix} \quad Q_{best} = []$$

Jovialul




$$\Phi = \begin{bmatrix} -2.1202 & -\text{Inf} & -2.1202 \\ -3.7297 & -\text{Inf} & -4.2205 \\ -6.7254 & -5.1567 & -5.3391 \end{bmatrix} \quad \Psi = \begin{bmatrix} 0 & 0 & 0 \\ 1 & 3 & 1 \\ 1 & 3 & \end{bmatrix} \quad Q_{best} = []$$

Jovialul




$$\Phi = \begin{bmatrix} -2.1202 & -\text{Inf} & -2.1202 \\ -3.7297 & -\text{Inf} & -4.2205 \\ -6.7254 & -5.1567 & -5.3391 \end{bmatrix} \quad \Psi = \begin{bmatrix} 0 & 0 & 0 \\ 1 & 3 & 1 \\ 1 & 3 & 1 \end{bmatrix} \quad Q_{best} = []$$

Jovialul




$$\Phi = \begin{bmatrix} -2.1202 & -\text{Inf} & -2.1202 \\ -3.7297 & -\text{Inf} & -4.2205 \\ -6.7254 & -5.1567 & -5.3391 \end{bmatrix} \quad \Psi = \begin{bmatrix} 0 & 0 & 0 \\ 1 & 3 & 1 \\ 1 & 3 & 1 \end{bmatrix} \quad Q_{best} = [\quad \quad \quad 2]$$

Jovialul



$$\Phi = \begin{bmatrix} -2.1202 & -\text{Inf} & -2.1202 \\ -3.7297 & -\text{Inf} & -4.2205 \\ -6.7254 & -5.1567 & -5.3391 \end{bmatrix} \quad \Psi = \begin{bmatrix} 0 & 0 & 0 \\ 1 & 3 & 1 \\ 1 & 3 & 1 \end{bmatrix} \quad Q_{best} = [\quad 1 \quad 2]$$

Jovialul



$$\Phi = \begin{bmatrix} -2.1202 & -\text{Inf} & -2.1202 \\ -3.7297 & -\text{Inf} & -4.2205 \\ -6.7254 & -5.1567 & -5.3391 \end{bmatrix} \quad \Psi = \begin{bmatrix} 0 & 0 & 0 \\ 1 & 3 & 1 \\ 1 & 3 & 1 \end{bmatrix} \quad Q_{best} = [1 \ 1 \ 2]$$



Algoritmul Viterbi

Algoritmul 4 Calculul celei mai probabile secvențe Q_{best}

```

for  $i = 1$  to  $N$  do
2:    $\phi_{1,i} \leftarrow \log(\pi_i) + \log(b_i(o_1))$ 
     $\psi_{1,i} \leftarrow 0$ 
4: end for
for  $t = 2$  to  $T$  do
6:   for  $i = 1$  to  $N$  do
       $\phi_{t,j} \leftarrow [\max_i \phi_{t-1,i} + \log(a_{i,j})] + \log(b_j(o_t))$ 
8:    $\psi_{t,i} \leftarrow \operatorname{argmax}_i \phi_{t-1,i} + \log(a_{i,j})$ 
end for
10: end for
     $\log(P(Q_{best}|O, \lambda)) \leftarrow \max_i \phi_{T,i}$ 
12:  $q_{T_{best}} \leftarrow \operatorname{argmax}_i \phi_{T,i}$ 
for  $t = T - 1$  to  $1$  do
14:    $q_{t_{best}} \leftarrow \psi_{t+1}(q_{t+1_{best}})$ 
end for

```



A venit vremea să scriem cod

- 1 Faceți o copie a fișierului `viterbi_disc.m.stub` și denumiți-o `viterbi_disc.m` (eliminați sufixul `.stub`).

Veți implementa funcția:

```
function [logP, Q] = viterbi_disc(O,Pi, A, B)
```



A venit vremea să scriem cod

- ① Faceți o copie a fișierului `viterbi_disc.m.stub` și denumiți-o `viterbi_disc.m` (eliminați sufixul `.stub`).

Veți implementa funcția:

```
function [logP, Q] = viterbi_disc(O, Pi, A, B)
```

- ② Completați cele două secțiuni.

```

1 %% Recursion
2 % phi_psi_disc-start – Write code below
3
4 % phi_psi_disc-end – Write code above
5 %% logP
6 [logP, Q(T)] = max(Phi(T, :));
7 %% Backtracking to compute the path Q
8 % path_disc-start – Write code below
9
10 % path_disc-end – Write code above

```

- ③ Folosiți `hmm_test` pentru a vă testa codul.



Outline

1 Aplicații în Învățarea Automată pentru MMA

- Învățarea Automată
- MMA în Învățarea Automată

2 Teoria MMA

- Cele Trei Probleme ale MMA
- Fundamente Matematice

3 Implementarea MMA

- Problema Evaluării: Algoritmul Forward-Backward
- Problema Interpretării: Algoritmul Viterbi
- **Problema Estimării: Algoritmul Baum-Welch**

4 Demo: Recunoașterea Simbolurilor

5 Tipuri de MMA

6 Discuții și Concluzii



Învățarea din observații - Amintire

Problema Estimării (Antrenării) Modelului

Dându-se un set de secvențe observate $\mathcal{O} = [O_1 O_2 \cdots O_L]$, cum ajustam parameterii $\lambda = (A, B, \Pi)$ ai unui MMA care încearcă să explice cel mai bine acele observații?



Învățarea din observații - Amintire

Problema Estimării (Antrenării) Modelului

Dându-se un set de secvențe observate $\mathcal{O} = [O_1 O_2 \cdots O_L]$, cum ajustam parameterii $\lambda = (A, B, \Pi)$ ai unui MMA care încearcă să explice cel mai bine acele observații?

Secvențele de observații folosite pentru ajustarea parametrilor modelului se numesc secvențe **de antrenare**.

Problema antrenării este esențială - ea permite crearea celor mai bune modele pentru fenomene reale.



Învățarea din observații - Abordare



Învățarea din observații - Abordare

Problemă

Nu se cunoaște o metodă analitică de căutare a parametrilor modelului care *maximizează probabilitatea secvențelor observate*.



Învățarea din observații - Abordare

Problemă

Nu se cunoaște o metodă analitică de căutare a parametrilor modelului care *maximizează probabilitatea secvențelor observate*.

Soluție

Putem totuși găsi $\lambda = (A, B, \Pi)$, astfel încât $\max_{\lambda} P(O|\lambda)$ corespunde unui **maxim local**, utilizând o **procedură iterativă** precum *algoritmul Baum-Welch*. Această metodă este o instanță a *algoritmului EM (Expectation Maximization)* [DLR77] pentru cazul MMA.



Algoritmul Baum-Welch (I)

Procedura în descriere conceptuală:

- ① Avem MMA $\lambda = (A, B, \Pi)$ și o secvență observată O



Algoritmul Baum-Welch (I)

Procedura în descriere conceptuală:

- ① Avem MMA $\lambda = (A, B, \Pi)$ și o secvență observată O
- ② Calculăm folosindu-ne de parametrii $\alpha_t(i)$ și $\beta_t(i)$
 - nr. estimat de tranzitii din S_i , pentru fiecare $1 \leq i \leq N$
 - nr. estimat de tranzitii din S_i la S_j , pentru fiecare $1 \leq i \leq N, 1 \leq j \leq N$
 - nr. estimat de vizite în S_j observând simbolul v_k , pentru fiecare $1 \leq j \leq N, 1 \leq k \leq M$



Algoritmul Baum-Welch (I)

Procedura în descriere conceptuală:

- ① Avem MMA $\lambda = (A, B, \Pi)$ și o secvență observată O
- ② Calculăm folosindu-ne de parametrii $\alpha_t(i)$ și $\beta_t(i)$
 - nr. estimat de tranzitii din S_i , pentru fiecare $1 \leq i \leq N$
 - nr. estimat de tranzitii din S_i la S_j , pentru fiecare $1 \leq i \leq N, 1 \leq j \leq N$
 - nr. estimat de vizite în S_j observând simbolul v_k , pentru fiecare $1 \leq j \leq N, 1 \leq k \leq M$
- ③ Dacă modelul este corect ne așteptăm ca
 - (a) $\Pi_i = \text{nr. estimat de vizite în starea } S_i \text{ la momentul } (t=1) = \bar{\Pi}_i$
 - (b) $a_{i,j} = \frac{\text{nr. estimat de tranzitii din } S_i \text{ la } S_j}{\text{nr. estimat de tranzitii din } S_i} = \bar{a}_{i,j}$
 - (c) $b_{j,k} = \frac{\text{nr. estimat de vizite în } S_j \text{ observând simbolul } v_k}{\text{nr. estimat de vizite în } S_j} = \bar{b}_{j,k}$



Algoritmul Baum-Welch (I)

Procedura în descriere conceptuală:

- ① Avem MMA $\lambda = (A, B, \Pi)$ și o secvență observată O
- ② Calculăm folosindu-ne de parametrii $\alpha_t(i)$ și $\beta_t(i)$
 - nr. estimat de tranzitii din S_i , pentru fiecare $1 \leq i \leq N$
 - nr. estimat de tranzitii din S_i la S_j , pentru fiecare $1 \leq i \leq N, 1 \leq j \leq N$
 - nr. estimat de vizite în S_j observând simbolul v_k , pentru fiecare $1 \leq j \leq N, 1 \leq k \leq M$
- ③ Dacă modelul este corect ne așteptăm ca
 - (a) $\Pi_i = \text{nr. estimat de vizite în starea } S_i \text{ la momentul } (t=1) = \bar{\Pi}_i$
 - (b) $a_{i,j} = \frac{\text{nr. estimat de tranzitii din } S_i \text{ la } S_j}{\text{nr. estimat de tranzitii din } S_i} = \bar{a}_{i,j}$
 - (c) $b_{j,k} = \frac{\text{nr. estimat de vizite în } S_j \text{ observând simbolul } v_k}{\text{nr. estimat de vizite în } S_j} = \bar{b}_{j,k}$
- ④ Vedem că raporturile calculate din presupunerea noastră explică mai bine observația decât parametrii anteriori, i.e. $P(O|\bar{\lambda}) > P(O|\lambda)$



Algoritmul Baum-Welch (I)

Procedura în descriere conceptuală:

- ① Avem MMA $\lambda = (A, B, \Pi)$ și o secvență observată O
- ② Calculăm folosindu-ne de parametrii $\alpha_t(i)$ și $\beta_t(i)$
 - nr. estimat de tranzitii din S_i , pentru fiecare $1 \leq i \leq N$
 - nr. estimat de tranzitii din S_i la S_j , pentru fiecare $1 \leq i \leq N, 1 \leq j \leq N$
 - nr. estimat de vizite în S_j observând simbolul v_k , pentru fiecare $1 \leq j \leq N, 1 \leq k \leq M$
- ③ Dacă modelul este corect ne așteptăm ca
 - (a) $\Pi_i = \text{nr. estimat de vizite în starea } S_i \text{ la momentul } (t=1) = \bar{\Pi}_i$
 - (b) $a_{i,j} = \frac{\text{nr. estimat de tranzitii din } S_i \text{ la } S_j}{\text{nr. estimat de tranzitii din } S_i} = \bar{a}_{i,j}$
 - (c) $b_{j,k} = \frac{\text{nr. estimat de vizite în } S_j \text{ observând simbolul } v_k}{\text{nr. estimat de vizite în } S_j} = \bar{b}_{j,k}$
- ④ Vedem că raporturile calculate din presupunerea noastră explică mai bine observația decât parametrii anteriori, i.e. $P(O|\bar{\lambda}) > P(O|\lambda)$
- ⑤ Atunci repetăm procesul până ce suntem mulțumiți (convergență): $P(O|\bar{\lambda}) - P(O|\lambda) \leq \epsilon$



Algoritmul Baum-Welch (II)



Algoritmul Baum-Welch (II)

Definim întâi niște variabile auxiliare:

$$\xi_{t,i,j} = \xi_t(i,j) = P(q_t = s_i, q_{t+1} = s_j | O, \lambda)$$

Probabilitatea de a fi în starea s_i la momentul t și în starea s_j la momentul $t + 1$, condiționat de parametrii modelului curent și secvența observată.



Algoritmul Baum-Welch (II)

Definim întâi niște variabile auxiliare:

$$\xi_{t,i,j} = \xi_t(i,j) = P(q_t = s_i, q_{t+1} = s_j | O, \lambda)$$

Probabilitatea de a fi în starea s_i la momentul t și în starea s_j la momentul $t + 1$, condiționat de parametrii modelului curent și secvența observată.

$$\gamma_{t,i} = \gamma_t(i) = P(q_t = s_i | O, \lambda)$$

Probabilitatea de a fi în starea s_i la momentul t , condiționat de parametrii modelului curent și secvența observată.



Algoritmul Baum-Welch (II)

Definim întâi niște variabile auxiliare:

$$\xi_{t,i,j} = \xi_t(i,j) = P(q_t = s_i, q_{t+1} = s_j | O, \lambda)$$

Probabilitatea de a fi în starea s_i la momentul t și în starea s_j la momentul $t + 1$, condiționat de parametrii modelului curent și secvența observată.


$$\gamma_{t,i} = \gamma_t(i) = P(q_t = s_i | O, \lambda)$$

Probabilitatea de a fi în starea s_i la momentul t , condiționat de parametrii modelului curent și secvența observată.

Din definiții rezultă că:

$$\gamma_t(i) = \sum_{j=1}^N \xi_t(i,j)$$

Algoritmul Baum-Welch (III)



$$\alpha_{t,i} = P(o_1, o_2, \dots, o_t, q_t = S_i | \lambda) \quad (36)$$

$$\beta_{t,i} = P(o_{t+1} o_{t+2} \cdots o_T | q_t = S_i, \lambda) \quad (37)$$

Secvența de operații necesară pentru calculul evenimentului mixt ca sistemul se află în starea S_i la momentul t și în starea S_j la momentul $t + 1$

$$\begin{aligned} \xi_t(i,j) &= \frac{\alpha_{t,i} \cdot a_{i,j} \cdot b_j(o_{t+1}) \cdot \beta_{t+1,j}}{P(O|\lambda)} \\ &= \frac{\alpha_{t,i} \cdot a_{i,j} \cdot b_j(o_{t+1}) \cdot \beta_{t+1,j}}{\sum_{k=1}^N \sum_{l=1}^N \alpha_{t,k} \cdot a_{k,l} \cdot b_l(o_{t+1}) \cdot \beta_{t+1,l}} \end{aligned} \quad (38)$$



Algoritmul Baum-Welch (IV)

Cum ne ajută aceste variabile auxiliare?

$$\sum_{t=1}^{T-1} \gamma_t(i) = \text{numărul estimat de tranziții din } S_i$$

$$\sum_{t=1}^{T-1} \xi_t(i,j) = \text{numărul estimat de tranziții din } S_i \text{ la } S_j$$



Algoritmul Baum-Welch (V)

$\bar{\pi}_i = \text{nr. estimat de vizite în starea } S_i \text{ la momentul } (t = 1) = \gamma_1(i)$ (39)



Algoritmul Baum-Welch (V)

$\bar{\pi}_i = \text{nr. estimat de vizite în starea } S_i \text{ la momentul } (t = 1) = \gamma_1(i)$ (39)

$$\begin{aligned} \bar{a}_{i,j} &= \frac{\text{nr. estimat de tranziții din } S_i \text{ la } S_j}{\text{nr. estimat de tranziții din } S_i} \\ &= \frac{\sum_{t=1}^{T-1} \xi_t(i, j)}{\sum_{t=1}^{T-1} \gamma_t(i)} \end{aligned} \quad (40)$$



Algoritmul Baum-Welch (V)

$$\bar{\pi}_i = \text{nr. estimat de vizite în starea } S_i \text{ la momentul } (t=1) = \gamma_1(i) \quad (39)$$

$$\begin{aligned} \bar{a}_{i,j} &= \frac{\text{nr. estimat de tranziții din } S_i \text{ la } S_j}{\text{nr. estimat de tranziții din } S_i} \\ &= \frac{\sum_{t=1}^{T-1} \xi_t(i, j)}{\sum_{t=1}^{T-1} \gamma_t(i)} \end{aligned} \quad (40)$$

$$\begin{aligned} \bar{b}_{j,k} &= \frac{\text{nr. estimat de vizite în } S_j \text{ observând simbolul } v_k}{\text{nr. estimat de vizite în } S_j} \\ &= \frac{\sum_{t=1, O_t=v_k}^T \gamma_t(j)}{\sum_{t=1}^T \gamma_t(j)} \end{aligned} \quad (41)$$



Algoritmul Baum-Welch (VI)

Algoritm 5 Algoritm Baum-Welch

```

1: intrări:  $O \leftarrow$  secvența de observații,  $\epsilon \leftarrow$  prag de convergență
2:
   {Initializare}
3: init. uniformă  $\Pi$  ( $\Pi_i = 1/N, 1 \leq i \leq N$ )
4: init. aleatoare  $a_{i,j}$ , a. î.  $\sum_{j=1}^N a_{i,j} = 1, \forall i = 1, \dots, N$ 
5: init. uniformă  $b_{j,k}$  ( $b_{j,k} = 1/M, 1 \leq j \leq N, 1 \leq k \leq M$ )
6: init  $\log(P(O|\bar{\lambda})) = 0$ 

7: repeat
8:    $\log(P(O|\lambda)) = \log(P(O|\bar{\lambda}))$ 
9:
   {E STEP - calculeaza variantele scalate pentru  $\alpha$  și  $\beta$  și probabilitatea curentă (log likelihood -  $\log(P(O|\bar{\lambda}))$ ) a secvenței observe}
10:   $[\log(P(O|\bar{\lambda})), \hat{\alpha}, \hat{\beta}, Scale] = forward\_backward(O, \Pi, A, B)$ 
11:
   {M STEP - recalculeaza  $\Pi$ ,  $A$  și  $B$ }
12:   $\Pi = update\_pi\_procedure(\hat{\alpha}, \hat{\beta}, Scale)$ 
13:   $A = update\_A\_procedure(O, \hat{\alpha}, \hat{\beta}, Scale)$ 
14:   $B = update\_B\_procedure(O, \hat{\alpha}, \hat{\beta}, Scale)$ 
15: until  $\log(P(O|\bar{\lambda})) - \log(P(O|\lambda)) < \epsilon$ 

```



Algoritmul Baum-Welch (VI)

Algoritm 6 Algoritm Baum-Welch

```

1: Function update_pi_procedure( $\hat{\alpha}$ ,  $\hat{\beta}$ , Scale)
2: for  $i = 1$  to  $N$  do
3:    $\Pi_i = \frac{\hat{\alpha}_1(i) \cdot \hat{\beta}_1(i) / Scale(1)}{\sum_{j=1}^N \hat{\alpha}_1(j) \cdot \hat{\beta}_1(j) / Scale(1)}$ 
4: end for
5: return  $\Pi$ 
6: EndFunction

7: Function update_A_procedure( $O$ ,  $\hat{\alpha}$ ,  $\hat{\beta}$ , Scale)
8: for  $i = 1$  to  $N$  do
9:   for  $j = 1$  to  $N$  do
10:     $a_{i,j} = \frac{\sum_{t=1}^{T-1} \hat{\alpha}_{t,i} \cdot a_{ij} \cdot b_j(o_{t+1}) \cdot \hat{\beta}_{t+1,j}}{\sum_{t=1}^{T-1} \sum_{j=1}^N \hat{\alpha}_{t,i} \cdot a_{i,j} \cdot b_j(o_{t+1}) \cdot \hat{\beta}_{t+1,j}}$ 
11:   end for
12: end for
13: return  $a$ 
14: EndFunction
  
```



Algoritmul Baum-Welch (VI)

Algoritm 7 Algoritm Baum-Welch

```
1: Function update_B_procedure( $O$ ,  $\hat{\alpha}$ ,  $\hat{\beta}$ , Scale)
2:   for  $j = 1$  to  $N$  do
3:     for  $k = 1$  to  $M$  do
4:        $b_{j,k} = \frac{\sum_{t=1, O(t)=v_k}^T \hat{\alpha}_t(j) \cdot \hat{\beta}_t(j) / Scale(t)}{\sum_{t=1}^T \hat{\alpha}_t(j) \cdot \hat{\beta}_t(j) / Scale(t)}$ 
5:     end for
6:   end for
7:   return  $b$ 
8: EndFunction
```



Baum-Welch - Să scriem niște cod

LET'S WRITE SOME CODE :-)



Aplicație de recunoaștere a simbolurilor

Features:



Aplicație de recunoaștere a simbolurilor

Features:

Definire

Definire, organizare și vizualizare a unui set de date de simboluri captate prin mișcarea mouse-ului.



Aplicație de recunoaștere a simbolurilor

Features:

Definire

Definire, organizare și vizualizare a unui set de date de simboluri captate prin mișcarea mouse-ului.

Antrenare

Antrenarea unui motor de recunoaștere a simbolurilor prin metoda MMA.



Aplicație de recunoaștere a simbolurilor

Features:

Definire

Definire, organizare și vizualizare a unui set de date de simboluri captate prin mișcarea mouse-ului.

Antrenare

Antrenarea unui motor de recunoaștere a simbolurilor prin metoda MMA.

Recunoaștere

Recunoașterea unui nou simbol și vizualizarea unor metriki de clasificare.



Aplicație de recunoaștere a simbolurilor

Features:

Definire

Definire, organizare și vizualizare a unui set de date de simboluri captate prin mișcarea mouse-ului.

Antrenare


Antrenarea unui motor de recunoaștere a simbolurilor prin metoda MMA.

Recunoaștere

Recunoașterea unui nou simbol și vizualizarea unor metrii de clasificare.

Simboluri default incluse: **săgeată stânga, săgeată dreapta, cerc, pătrat, infinit**


Aplicație de recunoaștere a simbolurilor - Preview



O vizualizare cu GUI-ul aplicației de recunoaștere a simbolurilor


Aplicație de recunoaștere a simbolurilor - Abordare

Adapted from [YX94].




Aplicație de recunoaștere a simbolurilor - Abordare

Adapted from [YX94].




Aplicație de recunoaștere a simbolurilor - Abordare

Adapted from [YX94].



Aplicație de recunoaștere a simbolurilor - Abordare

Adapted from [YX94].



Simplifying Assumption:

X-signal and Y-signal
are independent

Aplicație de recunoaștere a simbolurilor - Abordare

Adaptare după [YX94].

Structura MMA

$$N(\text{număr de stări}) = 8$$

2 variabile observabile de tip discrete per stare - $\text{coef}_{FFT}(x)$, $\text{coef}_{FFT}(y)$

$$M(\text{număr de valori pentru fiecare variabilă observabilă}) = 256$$

Modelul de tranziție:

- Bakis
- Ergodic



Aplicație de recunoaștere a simbolurilor - Abordare

Procedură de recunoaștere:

- ① Construim și antrenăm câte un MMA pentru fiecare simbol în parte



Aplicație de recunoaștere a simbolurilor - Abordare

Procedură de recunoaștere:

- ① Construim și antrenăm câte un MMA pentru fiecare simbol în parte
- ② Folosim un set de date (simboluri) de validare pentru a stabili *praguri* de recunoaștere, i.e. dacă probabilitatea secvenței observate este prea mică pentru fiecare MMA, marcăm simbolul drept *necunoscut*



Aplicație de recunoaștere a simbolurilor - Abordare

Procedură de recunoaștere:

- ① Construim și antrenăm câte un MMA pentru fiecare simbol în parte
- ② Folosim un set de date (simboluri) de validare pentru a stabili *praguri* de recunoaștere, i.e. dacă probabilitatea secvenței observate este prea mică pentru fiecare MMA, marcăm simbolul drept *necunoscut*
- ③ Recunoaștere:
 - Calculăm $P(O|\lambda_i)$ pentru fiecare MMA construit pentru simbolurile $i = 1, \dots, nr_simboluri$
 - Alegem $\max(P(O|\lambda_i))$ ca și simbol candidat. Dacă $P(O|\lambda_i) > prag_i$, atunci am recunoscut *simbolul i*, altfel marcăm *necunoscut*



Aplicație de recunoaștere a simbolurilor - Rezultate

Mărime set de date

5 simboluri: săgeată stânga, săgeată dreapta, cerc, pătrat, infinit

100 exemple per simbol: 50 antrenare, 10 validare, 40 testare

```
>> symbol_performance_test('ergodic')
----- Testing trained HMM models -----
## Results for the model of symbol "left_arrow":
Accuracy: 0.97500
Precision: 1.00000
Recall: 0.97500
Confusion matrix line: 39 0 1 0 0 0

## Results for the model of symbol "right_arrow":
Accuracy: 1.00000
Precision: 1.00000
Recall: 1.00000
Confusion matrix line: 0 40 0 0 0 0

## Results for the model of symbol "circle":
Accuracy: 0.90244
Precision: 0.97368
Recall: 0.92500
Confusion matrix line: 0 0 37 2 1 0

## Results for the model of symbol "square":
Accuracy: 0.95238
Precision: 0.95238
Recall: 1.00000
Confusion matrix line: 0 0 0 40 0 0

## Results for the model of symbol "infinity":
Accuracy: 0.97561
Precision: 0.97561
Recall: 1.00000
Confusion matrix line: 0 0 0 0 40 0
```

```
>> symbol_performance_test('bakis')
----- Testing trained HMM models -----
## Results for the model of symbol "left_arrow":
Accuracy: 0.90000
Precision: 1.00000
Recall: 0.90000
Confusion matrix line: 36 0 1 0 0 3

## Results for the model of symbol "right_arrow":
Accuracy: 1.00000
Precision: 1.00000
Recall: 1.00000
Confusion matrix line: 0 40 0 0 0 0

## Results for the model of symbol "circle":
Accuracy: 0.97561
Precision: 0.97561
Recall: 1.00000
Confusion matrix line: 0 0 40 0 0 0


## Results for the model of symbol "square":
Accuracy: 0.97500
Precision: 1.00000
Recall: 0.97500
Confusion matrix line: 0 0 0 39 0 1

## Results for the model of symbol "infinity":
Accuracy: 1.00000
Precision: 1.00000
Recall: 1.00000
Confusion matrix line: 0 0 0 0 40 0
```

Emisii continue

- Probabilitatea emisiilor este modelată cu o lege de distribuție continuă (e.g. normală).


$$b_j(o) = \mathcal{N}(o, \mu_j, \sigma_j^2) \quad (42)$$



Mixturi Gaussiene

- Probabilitatea emisiilor este modelată printr-o mixtură de distribuții normale.

$$b_j(o) = \sum_{k=1}^M c_{j,k} \mathcal{N}(o, \mu_{j,k}, \sigma_{j,k}^2) \quad (43)$$




Modele Markov Ergodice

Modele Markov Ergodice

Un lanț Markov se numește **ergodic** dacă din orice stare se poate ajunge în oricare altă stare (nu neapărat într-o singură mutare).


Lanțurile Markov ergodice se mai numesc și *ireductibile*.



Modelul Bakis

Modele Markov Bakis (stânga → dreapta)

Un model **Bakis** este unul în care nu este permisă tranziția dintr-o stare către o altă stare cu un indice mai mic.



- [DLR77] A.P. Dempster, N.M. Laird, and D.B. Rubin. Maximum likelihood from incomplete data via the em algorithm. *Journal of the Royal Statistical Society. Series B (Methodological)*, pages 1–38, 1977.
- [KF09] D. Koller and N. Friedman. *Probabilistic Graphical Models: Principles and Techniques*. MIT Press, 2009.
- [Mit97] Thomas M. Mitchell. *Machine Learning*. McGraw-Hill, Inc., New York, NY, USA, 1 edition, 1997.
- [Rab89] L.R. Rabiner. A tutorial on hidden markov models and selected applications in speech recognition. *Proceedings of the IEEE*, 77(2):257–286, 1989.
- [YX94] J. Yang and Y. Xu. Hidden markov model for gesture recognition. Technical report, DTIC Document, 1994.
- [Zub06] R. Zubek. Introduction to hidden markov models. *AI Game Programming Wisdom*, 3:633–646, 2006.



Thank you!

Baftă, şailor!